

北京理工大学

本科生毕业设计（论文）

面向桌面操作的 VLA 机械臂抓取与控制研究

Study on Grasping Strategy and Motion Control of VLA

Robotic Arm Oriented to Desktop Operation

学 院： 自动化学院

专 业： 自动化

班 级： 06212202

学生姓名： 唐元昊

学 号： 1120221074

指导教师： 方浩

2026 年 6 月 12 日

原创性声明

本人郑重声明：所呈交的毕业设计（论文），是本人在指导老师的指导下独立进行研究所取得的成果。除文中已经注明引用的内容外，本文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。

特此申明。

本人签名：唐元昊 日期：2026年6月10日

关于使用授权的声明

本人完全了解北京理工大学有关保管、使用毕业设计（论文）的规定，其中包括：①学校有权保管、并向有关部门送交本毕业设计（论文）的原件与复印件；②学校可以采用影印、缩印或其它复制手段复制并保存本毕业设计（论文）；③学校可允许本毕业设计（论文）被查阅或借阅；④学校可以学术交流为目的，复制赠送和交换本毕业设计（论文）；⑤学校可以公布本毕业设计（论文）的全部或部分内容。

本人签名：唐元昊 日期：2026年6月10日
指导老师签名：方晓 日期：2026年6月10日

面向桌面操作的 VLA 机械臂抓取与控制研究

摘 要

面向非结构化桌面的物体抓取与放置是服务机器人与智能产线的常见需求，视觉—语言—动作（VLA）模型能够融合多模态感知与自然语言指令，为复杂操作提供统一策略表示。然而从开源算法到实验室硬件，仍需在实时控制、数据规范与实机部署之间建立可复现闭环。本文以 Franka 七自由度机械臂与二指夹爪为平台，在 LeRobot 开源框架下扩展通用机器人与遥操作接口：实时侧采用基于 Franka 实时控制库与轨迹平滑的服务进程，上位机通过套接字与其解耦；实现 Franka 从机抽象及三维鼠标笛卡尔增量、同构主从关节空间两类示教方案，并给出两阶段配对标定流程以提升示教可重复性。在此基础上采集桌面苹果抓取任务数据，按 LeRobot v2.1 规范组织多路 RGB 与八维关节—夹爪状态及动作，得到小规模专用数据集。算法侧选取 $\pi_{0.5}$ VLA 模型，在预训练权重基础上完成观测—动作映射与任务微调。实机实验表明，分段同步闭环部署将抓取成功率由约 5% 提升至接近 100%，验证了闭环策略对接触敏感任务的决定性作用。此外，本文提出冻结骨干与短期记忆两项结构变体：冻结骨干通过参数路径过滤仅微调动作专家，训练显存由约 160 GB 降至约 60 GB（批尺寸为 4）且成功率达 90%；短期记忆变体引入空间-时间可分离注意力机制压缩历史帧信息，成功率提升至 100%。全文形成了从底层接入、示教采集、模型训练到在线控制的完整技术路线，可为同类平台落地提供工程参考。

关键词：视觉—语言—动作模型；弗兰卡机械臂；模仿学习；桌面抓取； $\pi_{0.5}$

Study on Grasping Strategy and Motion Control of VLA Robotic Arm Oriented to Desktop Operation

Abstract

Unstructured desktop pick-and-place is a common requirement in service robotics and intelligent automation. Vision-language-action (VLA) models integrate multimodal perception with natural language instructions, offering a unified policy for complex manipulation. Bridging open-source algorithms to laboratory hardware, however, still requires a reproducible closed loop across real-time control, data standardization, and physical deployment. This thesis targets a Franka 7-DoF arm with a parallel gripper. Within the LeRobot framework, we extend the generic robot and teleoperation interfaces with a socket-based real-time control service, a Franka follower abstraction, and two teaching schemes—SpaceMouse Cartesian teleoperation and homomorphic leader–follower joint-space teaching—supported by a two-stage pairing calibration. We then collect desktop apple-grasp demonstrations following the LeRobot v2.1 specification, producing a small-scale dataset with multi-view RGB and eight-dimensional joint–gripper state and actions. On the algorithm side, we fine-tune a $\pi_{0.5}$ VLA model from pretrained weights. Hardware experiments show that a segmented synchronous closed-loop deployment raises the grasp success rate from about 5% to nearly 100%, confirming the decisive role of closed-loop strategies for contact-sensitive tasks. Furthermore, we propose two structural variants: frozen backbone, which freezes the VLM backbone and fine-tunes only the action expert, reducing training GPU memory from about 160 GB to 60 GB while achieving 90% success; and short-term memory, which introduces space-time separable attention to compress historical frames, reaching 100% success. The full work delivers an end-to-end pipeline spanning system integration, demonstration collection, model training, and online control, serving as an engineering reference for similar platform bring-up.

Key Words: Vision-language-action model; Franka manipulator; imitation learning; desktop grasping; $\pi_{0.5}$

目 录

摘 要	I
Abstract	II
第 1 章 绪论	1
1.1 研究背景与意义	1
1.1.1 研究背景	1
1.1.2 研究问题与研究目标	1
1.2 国内外研究现状	2
1.2.1 视觉—语言对齐与空间推理	2
1.2.2 具身基础模型、开源 VLA 与动作生成	2
1.2.3 遥操作、桌面操作与部署共识	3
1.3 本文组织架构	4
1.3.1 研究方法与实验环境	4
1.3.2 实验方案与技术路线	6
1.3.3 设计任务与指标体系	6
1.4 主要贡献与创新点	8
第 2 章 弗兰卡平台系统集成与示教数据采集	9
2.1 系统总体架构	9
2.1.1 四层架构设计	9
2.1.2 主要软件模块	10
2.2 弗兰卡实时控制与底层通信	10
2.2.1 控制环路与时序性	10
2.2.2 套接字协议与上下位机分工	11
2.3 LeRobot 通用机器人接口扩展	11
2.3.1 框架约定与工厂注册	11
2.3.2 机器人抽象的设计要点	12
2.3.3 带末端夹爪的复合机器人	12
2.4 遥操作方案设计	13
2.4.1 三维鼠标遥操作	13
2.4.2 同构主从遥操作	14
2.4.3 与录制管线的衔接	16

2.5 桌面抓取示教数据采集与 LeRobot 数据集规范	17
2.5.1 采集任务与录制流程	17
2.5.2 LeRobot v2.1 数据集组织	18
2.5.3 帧级特征模式	18
2.5.4 数据规模与质量保障	19
第 3 章 基于 $\pi_{0.5}$ 的抓取策略训练与实机部署	20
3.1 $\pi_{0.5}$ 的核心原理框架	20
3.1.1 从 VLA 到分层推理	20
3.1.2 统一多模态序列建模	21
3.1.3 主干网络与动作专家	22
3.1.4 动作专家中的 Flow Matching 机制	23
3.1.5 离散动作预训练与连续动作后训练	24
3.1.6 异构数据协同训练的意义	24
3.2 面向桌面抓取的模型适配与训练实现	25
3.2.1 任务观测与动作空间重定义	25
3.2.2 训练配置与关键超参数	25
3.2.3 本文对 $\pi_{0.5}$ 的适配工作	26
3.3 在线推理执行策略与实机效果分析	27
3.3.1 两种部署方式的差异	27
3.3.2 成功率差异的原因分析	27
3.3.3 实验现象与任务完成质量	28
3.4 全量微调基线性能	30
第 4 章 $\pi_{0.5}$ 模型结构改进	31
4.1 基于参数路径过滤的冻结骨干机制	31
4.1.1 问题分析：小样本全量微调的风险	31
4.1.2 OpenPI 框架的参数冻结基础设施	31
4.1.3 配置实现与实验效果	32
4.2 短期记忆变体	33
4.2.1 问题分析：单帧视觉编码在桌面抓取中的局限	33
4.2.2 MEM 式短期记忆视频编码器的核心原理	34
4.2.3 本文实现与关键参数	35
4.2.4 行为效应与实验验证	36
4.3 模型变体综合对比与启示	37

结 论	39
参考文献	41
附 录	43
附录 A 缩略语与符号说明	43
附录 B 实验与工程环境概要	43
附录 C LeRobot 配置类型速查	44
致 谢	45

第 1 章 绪论

1.1 研究背景与意义

1.1.1 研究背景

面向非结构化环境的机械臂操作是机器人学与人工智能交叉研究的前沿方向。近年来，视觉-语言-动作（Vision-Language-Action, VLA）模型将多模态大模型的语义理解与机器人动作生成相统一，为“自然语言条件下的灵巧操作”提供了新的技术路径^[1-2]。与此同时，工业界与学术界相继开源了面向模仿学习与数据标准化的软件栈（如 Hugging Face LeRobot），降低了数据采集与策略训练的工程门槛。然而，从公开算法到具体实验室的异构硬件（高精度力控臂、多路相机、实时控制链路），中间仍普遍存在接口割裂、时序对齐困难、示教可重复性差等问题；尤其是面向 $\pi_{0.5}$ 等新一代分层 VLA 的部署，往往要求稳定的底层执行、与通用数据集规范对齐的观测-动作字段、以及可诊断的在线闭环，这些能力难以仅靠“更换若干超参数”获得。

在此背景下，领域重要性体现在两方面。首先，桌面抓取与放置类任务在物流分拣、实验室自动化与服务场景需求广泛，且同时考验全局场景理解与接触阶段的精细反馈；其次，VLA 的论文级结果多在特定机器人形态与数据规模下呈现，若缺少与本平台一致的全栈贯通，则难以判断性能瓶颈究竟来自模型、数据还是部署方式。本实验室在引进弗兰卡等先进臂式平台并探索 VLA 软硬件闭环的过程中，围绕实时控制、开源框架扩展与策略实装等关键环节开展系统性建设。本文作为该建设链条中“桌面抓取”方向的阶段性工作，独立完成了从硬件接入、示教采集、模型训练到实机闭环评测的全栈技术链路。作者与课题组其他成员在平台搭建与数据采集等环节存在合理分工协作，但本文所涉及的系统设计、接口实现、训练方案与实验分析均由作者主导完成。

1.1.2 研究问题与研究目标

研究问题。本文围绕 VLA 机械臂桌面操作的全栈落地，重点探讨三个层次的问题。首先，在系统集成层面，如何将弗兰卡实时控制与 LeRobot 通用机器人/遥操作抽象对接，使观测-动作模式定义、录制流程与后续训练入口保持一致？其次，在数据层面，如何组织面向桌面抓取的多相机示教数据，使其符合 LeRobot v2.1 规范并

支撑 $\pi_{0.5}$ 微调？最后，在算法与部署层面，在有限样本条件下， $\pi_{0.5}$ 经迁移训练后能否完成静平台单臂抓取—搬运—放置，以及在线执行策略如何影响成功率与失败恢复？

研究目标。本文旨在构建“底层执行—数据采集—模型训练—实机部署”的闭环系统；以苹果抓取并放置至指定区域为任务实例，完成可复现的接口扩展、数据集构建、 $\pi_{0.5}$ 训练配置与对比实验，并形成可推广的部署经验。

研究假设。本文提出两项研究假设。假设 H1（迁移可行性）认为，在加载 $\pi_{0.5}$ 预训练权重的前提下，规模在数十条轨迹量级的 LeRobot 规范数据集足以支撑桌面窄分布任务的微调，使策略学到稳定的粗定位—对准—夹取—搬运行行为模式。假设 H2（闭环敏感性）认为，对于易滑移、强接触的桌面物体，短时域动作块执行与高频重推理的部署方式相比偏异步、长开环的执行方式，将显著提升抓取成功率与过程稳定性；性能差异主要归因于闭环方式而非单一权重差异。

1.2 国内外研究现状

1.2.1 视觉—语言对齐与空间推理

在 VLA 之前就已有大量工作探索如何将语言与可操作视觉表征结合。Cliport^[3] 将 CLIP 式语义与“where”空间变换网络结合，实现语言条件下的桌面抓取；SayCan^[4] 用语言模型产生子任务，再用价值函数筛选当前环境下可执行的一步，缓解“会说不会做”；VIMA^[5] 则支持图文交错的多模态提示，为“指图操作”类交互奠定基础。这一阶段的工作说明：仅有语言或仅有像素都不足以应对长程操作，跨模态对齐与可执行性约束必须协同设计。

在空间推理与三维世界建模方面，SpatialVLM^[6] 赋予 VLM 度量级空间判断能力；3D-VLA^[7] 将动作生成与三维世界建模耦合，面向长程后果预测；Surfer^[8] 则以世界模型显式预测场景状态转移，为语言条件操作中的动作选择与物理后果建模提供了另一类思路；OK-Robot^[9] 系统分析了“堆叠开放知识模块”时真正决定成败的工程要素，对无再训练或少再训练的快速部署具有参考价值。

1.2.2 具身基础模型、开源 VLA 与动作生成

PaLM-E^[10] 将机器人感知流注入超大语言模型，实现长程规划与场景理解；RoboCat^[11] 强调自改进与跨机械臂形态迁移；体素化动作建模方面，Perceiver-Actor^[12] 在三维占用栅格上输出动作，有利于遮挡与多物体堆叠。当前社区主流进一步转向以

真机机器人数据与统一数据模式定义为约束的高容量策略网络，而非仅在仿真或单一形态上验证的通才演示。国内关于多模态大模型具身智能体的综述也将具身感知、任务规划与低层动作控制作为关键组成，说明 VLA 正在从单点模型演进为覆盖感知、规划和执行的系统方法^[13]。

在从大规模预训练到开源 VLA 的演进中，RT-1^[14] 证明在超大规模真机数据上训练的高容量模型可获得鲁棒策略；RT-2^[15] 将网络图文先验与离散动作 token 结合，使“网络知识”可迁移到机器人控制；Open X-Embodiment^[16] 联合多实验室、多本体数据训练 RT-X，标志着跨硬件统计迁移成为社区共识。开源侧，OpenVLA^[17] 与 Octo^[18] 提供了可本地微调、可替换相机与语言条件的通用策略；RoboFlamingo-Plus^[19] 则进一步融合深度与 RGB，缓解纯二维投影造成的深度歧义。

在仿真、数据编排与生成式 VLA 方向，RoboCasa^[20]、ManiSkill3^[21] 等强调大规模仿真与 GPU 并行，用于弥补真实示教成本；AutoRT^[22] 展示如何用具身大模型编排多台机台采集；GR-2^[23] 探索视频—语言先验向机器人动作的生成式迁移。扩散模型在具身模仿学习中的应用也受到系统总结，其优势在于能够表达多峰动作分布，并通过迭代去噪机制生成平滑、稳定的操作轨迹^[24]。在学习机制层面， $\pi_{0.6}^*$ ^[25] 引入经验学习与修正闭环，FAST^[26] 与知识绝缘^[27] 则从动作分词与训练效率角度推进 VLA。

在连续动作建模方面， π_0 ^[1]、 $\pi_{0.5}$ ^[2] 将预训练视觉—语言主干（如 PaliGemma^[28]）与动作专家结合，并以 flow matching^[29] 建模连续动作分布，代表当前面向真机高频控制的一条主流路线。本文即以 $\pi_{0.5}$ 为主线，在其开放权重与训练栈上进行任务迁移。

1.2.3 遥操作、桌面操作与部署共识

Mobile ALOHA^[30] 与 ALOHA Unleashed^[31] 推动低成本的全局示教与复杂双手技能；APT^[32] 用任意点轨迹统一可形变物体与刚体操作，为动作表示提供新视角。这些数据范式与 LeRobot 的统一张量规范相衔接，使社区能够快速沉淀可训练数据集。

在桌面操作与部署侧，桌面抓取在几何约束、摩擦与滚动等非结构扰动下对接触瞬间的闭环修正极为敏感。既有研究既关注抓取规划与学习型策略本身，也日益重视推理频率、动作块执行方式与异步/同步控制对成功率的影响；但在公开讨论中，同一训练权重在不同部署脚本下的巨大性能落差仍相对缺乏系统记录，尤其对 VLA 动作块输出而言，部署策略往往与模型结构同等关键。此外，抓取后的物理属性变

化与载荷适应也会影响闭环控制稳定性，例如 FlyAware^[33] 通过视觉估计与抓后适应处理空中操作中的惯性变化，提示接触后的在线校正同样是机器人操作系统的重要环节。

现有研究的不足与研究空白。综合上述脉络，现有工作尚存在以下与本文课题密切相关的研究空白。

首先，平台落地鸿沟。公开 VLA 与 LeRobot 生态多以若干“标准型”机器人为第一公民，弗兰卡等平台若缺少与 Robot/Teleoperator 约定一致的实现，则难以直接复用社区训练脚本，更无法保证示教数据与策略消费端的字段一一对应；而跨本体成果^[16-18]虽强，仍不能自动消解单平台线缆级工程问题。

其次，示教质量与可复现性。低成本遥操作^[30-31]与灵活轨迹表示^[32]为数据提供了方法学支撑，但安装误差、轴向反向与夹爪量程不一致会导致关节空间系统偏差；若缺少可文件化、可自动解算的标定流程，则小规模高质量数据难以稳定获得，仿真合成数据^[20-21]亦无法替代本机一致性。

再次，小规模专用数据下的迁移验证。 $\pi_{0.5}$ ^[2] 原论文面向移动双臂与高覆盖多相机配置，而静态单臂桌面任务的观测—动作维度更紧凑；如何在十余小时以下、数十条轨迹量级完成可用的任务特化微调，并与实机接口严格对齐，仍需面向具体平台给出可检验的实现路径——这与开放世界报告^[2,25]形成互补问题。

最后，部署闭环与性能解释。动作块预测^[26]在理论上利于平滑与快速推理，但若在线执行仍偏长时开环，接触敏感任务可能出现成功率坍塌；现有文献对“同一模型、不同闭环脚本”的对比往往不足，且空间/三维推理增强^[6-8]与开放系统集成经验^[9]很少落实到弗兰卡 + 双相机 + VLA 权重这一典型教学实验配置上。

由此，本文将问题凝练为：在实验室自建弗兰卡–LeRobot–OpenPI ($\pi_{0.5}$) 全流程的前提下，能否以标准化示教数据与针对性接口适配，在桌面抓取任务上实现可用的 VLA 策略，并厘清部署闭环对实机性能的决定性作用？

1.3 本文组织架构

1.3.1 研究方法与环境

本节概述全文采用的工程与研究思路，并给出实验场所软硬件条件及拟开展的实验内容；其中软硬件配置汇总见表 1-1。

（1）硬件环境。机械臂：Franka FR3 协作机械臂（7-DoF，重复定位精度约

$\pm 0.1\text{ mm}$ ），末端配备知行 CTAG2F90C 双指夹爪。感知设备：腕部末端安装 Intel RealSense D445 深度相机（RGB 分辨率 $640 \times 480@30\text{ Hz}$ ，深度量程约 $0.1\text{--}10\text{ m}$ ），获取手眼视角；若配置固定场景机位，则与腕部相机形成互补双视角，外参与同步策略在第二章统一约定。计算设备：实验室配备 NVIDIA RTX A6000 显卡（4 张）、Intel Xeon Platinum 8336C 处理器（2 路，32 核 64 线程/路）、DDR4 内存（8 条，每条 32 GB），用于模型训练与高频推理实验。桌面场景：标准办公桌（ $120\text{ cm} \times 60\text{ cm}$ ），摆放笔具、积木、文件、杯子等常见物件；辅以可调照度 LED 光源（约 $500\text{--}2000\text{ lux}$ ），便于考察光照变化对感知的影响。

（2）软件环境。操作系统采用 Ubuntu 22.04 LTS。深度学习侧以 PyTorch 2.1 为主进行模型训练；机械臂实时控制沿用第二章所述基于 libfranka 与轨迹平滑的实时控制服务，上位机经套接字协议与 LeRobot 客户端协同。机器人数据与遥控录制依托 LeRobot SDK（v2.1 数据布局）；若需与导航、多传感器节点联动，可在同一操作系统上按需启用 ROS 2 相关接口封装作为辅助中间件。数据处理与可视化采用 NumPy、Matplotlib，抽检与调试辅以 Rerun 等工具。

表 1-1 实验平台软硬件条件一览

类别	项目	配置说明
硬件	机械臂与夹爪	Franka FR3（7-DoF，重复定位精度约 $\pm 0.1\text{ mm}$ ）；知行 CTAG2F90C 双指夹爪
	视觉传感器	Intel RealSense D445（腕部手眼；RGB $640 \times 480@30\text{ Hz}$ ；深度约 $0.1\text{--}10\text{ m}$ ）；可选场景固定机位构成双视角
	计算节点	RTX A6000 $\times 4$ ；Xeon Platinum 8336C $\times 2$ （32C64T/路）；DDR4 32 GB $\times 8$
	场景与光照 网络与控制	办公桌 $120 \times 60\text{ cm}$ ；典型桌面杂物； 局域网连接 RT PC（运行实时控制服务）与训练/推理工作站；千兆以太网等
软件	系统与运行时	Ubuntu 22.04 LTS；Python 虚拟环境与依赖锁定
	训练框架	PyTorch 2.1；OpenPI/ $\pi_{0.5}$ 训练配置（见第三章）
	机器人与数据	LeRobot SDK；实时控制服务（libfranka）；可选 ROS 2 栈
	辅助工具	NumPy；Matplotlib；Rerun（录制质量抽检）

1.3.2 实验方案与技术路线

实验内容初步归纳为三个方面。首先是桌面操作数据集构建：预定采集覆盖多类物体（如苹果、正方体积木等），规模不少于 30 条有效轨迹，每条轨迹包含约 200–500 帧多模态数据，严格遵循 LeRobot v2.1 规范并在采集管线侧通过时间戳对齐。其次是模型训练与微调：在 $\pi_{0.5}$ 开源权重基础上，将第二章构建的数据集接入 OpenPI 训练接口，采用任务特化微调策略，并在训练过程中监控损失及离线指标。最后是系统测试与性能评估：在若干代表性场景下评测抓取成功率、末端定位误差及指令跟随正确率，并对比遮挡、照度变化等条件下的性能衰减，分析感知与动作生成链条中的薄弱环节。

以上三方面内容分别对应第二章（系统集成与数据采集）和第三章（模型训练与实机评测），具体方案与指标见表 1-2。

1.3.3 设计任务与指标体系

为将“系统集成—数据采集—模型训练—实机评测”的全栈目标落实为可检验的具体任务，本文将毕设工作分解为四项设计任务，每项任务有明确的方案策略、量化指标与对应论文章节。表 1-2 给出任务—策略—指标的对照总览。

设计任务详述如下。

T1：弗兰卡实时控制与 LeRobot 接口扩展。设计目标是使 Franka FR3 机械臂被 LeRobot 框架视为标准机器人，从而可复用社区录制与训练工具链。方案上，首先在 RT PC 部署基于 libfranka 与 Ruckig 的实时服务进程，通过 TCP 套接字与上位机解耦；其次在 LeRobot 工厂中注册机器人抽象，将关节状态、夹爪开合度与多相机 RGB 映射为标准张量字典；再次实现三维鼠标笛卡尔增量遥操作（适用于快速粗定位）与同构主从关节空间遥操作（适用于精细接触阶段）两种示教入口；最后设计两阶段配对标定流程，自动解算七轴缩放偏置与夹爪量程并将结果版本化。考核指标：控制频率 $\geq 30\text{ Hz}$ ；标定后主从关节偏差均值 $< 1^\circ$ ；支持社区录制工具直接录制。

T2：桌面抓取示教数据采集与规范化。设计目标是以“抓取绿色苹果并放置至桌面左上角”为任务实例，采集符合 LeRobot v2.1 规范的桌面抓取数据集。方案上，采用第三人称固定相机与腕部手眼相机的双视角布局，以 10 Hz 帧率同步录制，在接触敏感阶段通过同构主从臂完成精细示教；按 LeRobot v2.1 目录结构将任务语义与轨迹信息存入元数据目录，帧级表格以列式存储格式存放，视频轨道单独挂载；在元

北京理工大学本科生毕业设计（论文）

表 1-2 毕业设计任务分解

设计任务	方案/策略	考核指标	对应章节
T1: 弗兰卡实时控制与 LeRobot 接口扩展	四层架构（实时层 → 网络层 → 抽象层 → 遥操作层）；实现弗兰卡机器人抽象与三维鼠标/同构主从两种遥操作入口；两阶段配对标定	控制频率 $\geq 30\text{ Hz}$ ；遥操作轨迹可复现性（标定后关节偏差 $< 1^\circ$ ）；支持社区录制工具直接录制	第二章
T2: 桌面抓取示教数据采集与规范化	LeRobot v2.1 格式；双相机（第三人称 + 腕部）；10 Hz 帧率；任务语义标注	≥ 30 条有效轨迹；每条 ≥ 150 帧；字段模式定义与 OpenPI 训练入口完全对齐	第二章
T3: $\pi_{0.5}$ 模型迁移与变体改进	全量微调基线 + 冻结骨干轻量化变体 + 短期记忆变体；观测/动作空间重映射；Flow Matching 训练	抓取成功率量化（10 次测试）；显存占用对比；失败恢复行为记录	第三章、第四章
T4: 实机闭环部署与在线执行策略对比	异步远程客户端 vs. 分段同步闭环；动作块截取执行（3–10 步/次）；高频重推理	同一权重下两种部署方式的成功率差异；闭环策略成功率目标 $\geq 90\%$	第三章

信息中明确定义 8 维状态与动作特征的类型与形状，确保与训练管线字段一致。考核指标： ≥ 30 条有效轨迹，总帧数 $\geq 5,000$ ；字段与 OpenPI 训练入口完全对齐，无需中间转换。

T3: $\pi_{0.5}$ 模型迁移与变体改进。设计目标是将 $\pi_{0.5}$ 预训练权重迁移至桌面抓取任务，并针对小样本、接触敏感的特性设计模型变体。方案上，首先将双相机映射为全局与手眼两路视觉输入，8 维状态/动作与 LeRobot 标准字段对齐，动作块长度设为 32；其次加载预训练权重完成全量微调作为实验基线；进而利用参数路径过滤机制精确冻结 VLM 骨干而仅微调动作专家，目标是将训练显存由约 160 GB 降至约 60 GB 且成功率不降；同时基于空间-时间可分离注意力机制构造短期记忆变体，当前帧保留完整空间细节、历史帧压缩为少量摘要 token，目标成功率 $\geq 90\%$ 并具备失败恢复能力。两项改进详见第四章。考核指标：全量微调基线成功率 $\geq 75\%$ ；冻结骨干变体训练显存约 60 GB，成功率不低于基线；短期记忆变体成功率 $\geq 90\%$ ，并记录到自主失败恢复行为。

T4: 实机闭环部署与在线执行策略对比。设计目标是量化不同在线执行策略对

同一 VLA 权重在接触敏感任务上的性能影响，验证部署策略与模型结构同等重要的假设。方案上，实现异步远端推理（执行完整动作块，偏长时开环）与分段同步闭环（每次仅执行一小段，约 0.27 s 后重观测再推理）两种部署方式，使用同一模型权重在相同桌面场景下各进行 10 次抓取测试，记录成功率与失败模式。考核指标：分段同步闭环成功率 $\geq 90\%$ ；两种部署方式成功率差异 ≥ 50 个百分点，验证闭环策略的决定性作用。

1.4 主要贡献与创新点

综合上述设计任务与实验结果，本文的主要贡献与创新点归纳如下。

首先，弗兰卡-LeRobot 一体化接口实现与可版本化标定链路。将实时控制、LeRobot Robot 抽象与多种遥操作入口统一在同一数据录制语义下，降低与 $\pi_{0.5}$ /OpenPI 训练栈的对接成本；通过两阶段配对标定将关节缩放偏置与夹爪量程写入可版本化 JSON 配置，显著提升示教轨迹在装配与零点误差条件下的可重复性（T1）。

其次，符合社区规范的小规模桌面抓取数据集。以自采桌面抓取数据集（30 条轨迹，5,512 帧，双相机 RGB + 8 维状态/动作）为实例，展示任务语义、双相机互补视角与帧级特征如何嵌入 LeRobot v2.1 格式，为小样本 VLA 微调提供可直接消费的数据基础（T2）。

再次， $\pi_{0.5}$ 向静平台桌面任务的迁移适配与模型结构改进。完成观测-动作空间重定义与训练配置适配；提出基于参数路径过滤的冻结骨干轻量化策略（训练显存由约 160 GB 降至约 60 GB，批次大小为 4，成功率 90%）和基于空间-时间可分离注意力机制的短期记忆变体（成功率 100%，具有自主失败恢复能力），两项改进通过配置驱动设计（T3）。

最后，在线闭环策略对接触敏感任务决定性作用的系统验证。在同一模型权重下，分段同步闭环将抓取成功率从约 5%（异步开环）提升至接近 100%（分段闭环），通过受控对比实验量化了部署策略对实机性能的影响量级，为 VLA 在类似接触富集任务中的部署提供了可操作的经验准则（T4）。

第 2 章 弗兰卡平台系统集成与示教数据采集

本章对应设计任务 T1（弗兰卡实时控制与 LeRobot 接口扩展）与 T2（桌面抓取示教数据采集与 LeRobot v2.1 规范化）。设计目标是使 Franka FR3 机械臂被 LeRobot 框架视为标准机器人，从而可复用社区录制与训练工具链，并在此基础上以桌面抓取为实例完成标准化示教数据采集。

全章按“底层执行—框架抽象—人机接口—数据闭环”的层次展开。第二节给出系统四层架构总图与模块职责概览；第三节阐述实时控制与上下位机通信的设计要点；第四节说明如何将弗兰卡平台纳入 LeRobot 的通用机器人抽象，以及带夹爪复合机器人的建模方式；第五节介绍三维鼠标与同构主从两类遥操作方案，并重点给出两阶段配对标定的数学模型与流程；第六节以自采数据集为实例，展示 LeRobot v2.1 规范下的数据组织、特征模式与质量保障措施。

2.1 系统总体架构

2.1.1 四层架构设计

本文将机器人数据采集平台划分为四层，如图 2-1 所示。各层职责分明，层间通过明确的协议或接口约定解耦，使得实时控制、机器人抽象、遥操作与数据落盘可以独立开发与调试。

第一层为实时执行层，部署于机器人实时控制计算机（RT PC）。该层基于官方 libfranka 库与弗兰卡控制器进行底层通信，并引入 Ruckig 轨迹平滑库对指令做时间参数化，抑制示教或上层指令中的突变，保证 1 kHz 伺服周期内的确定性执行。

第二层为网络服务层，通过 TCP 套接字将实时侧与控制计算侧解耦。上位机以文本行协议发送关节目标等指令并接收状态反馈，使实时侧仅需维护体量可控的服务端构建产物，上位机则可使用与实验室计算环境一致的 Python 版本与依赖栈。

第三层为 LeRobot 抽象层，在 LeRobot 的 Robot/RobotConfig 约定下实现机器人抽象（FrankaFER 及其夹爪复合配置），将多相机 RGB/深度、关节状态、末端位姿等观测与关节目标等动作统一为张量字典接口，使本平台在框架语义下与社区已有的 Koch、SO-100 等机器人等价。

第四层为遥操作与数据层，实现三维鼠标笛卡尔增量映射与同构主从关节映射




图 2-1 系统四层架构

两类示教入口，并在 LeRobot 数据集规范下完成多相机—关节状态的时间对齐与字段命名，支撑高质量示教采集。

2.1.2 主要软件模块

表 2-1 汇总了平台的主要软件模块及其职责，按所在层次排列。

2.2 弗兰卡实时控制与底层通信

2.2.1 控制环路与实时性

弗兰卡机械臂的官方控制接口对实时性有严格要求。本文将低层控制集中于 RT PC 上的 C++ 服务进程，避免在非实时操作系统上与 Python 解释器抢占同一调度上下文，从而降低控制超时风险。服务进程基于 libfranka 读取机器人状态并下发轨迹或目标，同时引入 Ruckig 对指令进行时间参数化和平滑处理，提高执行过程的可重复性与安全性。

表 2-1 平台主要模块与功能

模块	所属层次	主要职责
实时控制服务	第一层（实时执行）	1 kHz 伺服、轨迹平滑、状态回传
弗兰卡从臂客户端	第二、三层	套接字通信、观测与动作特征管理、连接生命周期
臂 + 夹爪复合配置	第三层	七轴关节 + 夹爪开合的八维一体化观测与动作
三维鼠标遥操作	第四层	鼠标增量—累积位姿—逆运动学—关节目标
同构主从遥操作	第四层	主臂读数经缩放偏置映射为从臂关节目标
配对标定工具	第四层（辅助）	自动解算关节缩放偏置与夹爪量程，输出配置文件
数据录制管线	第四层	LeRobot v2.1 格式的多相机—关节同步录制与落盘

2.2.2 套接字协议与上下位机分工

上层 LeRobot 进程不直接调用 libfranka，而是通过 TCP 套接字与实时控制服务进程通信：连接建立后，以换行分隔的文本命令进行请求—应答式交互。该设计的优点在于：首先，上位机可使用与实验室计算环境一致的 Python 版本与依赖栈，便于与 LeRobot、PyTorch 等工具链共存；其次，实时机仅需维护体量可控的服务端构建产物与少量系统依赖，部署边界清晰；最后，便于在局域网内将相机与推理节点与机械臂分机关联，扩展多机协作时的拓扑。

启动数据采集或控制脚本前，须在 RT PC 上先启动实时控制服务并传入机器人 IP，确认健康检查通过后再在上位机侧实例化机器人客户端，以避免“接口已初始化但执行端未就绪”的连接语义错误。

2.3 LeRobot 通用机器人接口扩展

2.3.1 框架约定与工厂注册

LeRobot 将物理平台抽象为 Robot 子类，并通过 RobotConfig 数据类配置（含 type 字段）在工厂函数中派生具体实现。本文在工厂注册中增加了对应系列类型，使标准命令行工具与录制脚本能够以与其他官方机器人相同的方式构造从臂（Follower），无需在外部维护专用启动器。

2.3.2 机器人抽象的设计要点

弗兰卡机器人抽象（FrankaFER）的核心职责包括以下三点。

在连接与生命周期管理方面，配置项中提供实时服务端 IP 与端口；实例化时建立阻塞或非阻塞套接字，并在断开、异常时清理文件描述符，向上层暴露连接状态查询接口，便于录制脚本在断连时安全退出。

在观测特征声明方面，对齐 LeRobot 数据集模式，显式声明各观测键名及类型：七自由度关节位置与速度、末端执行器位姿（以行优先 4×4 齐次变换矩阵展平为十六维向量）、以及按相机名称组织的 RGB 张量；若启用 RealSense 等相机的深度流，则同步声明对应深度图键名与形状。该声明在录制时用于分配缓冲区与校验字段完备性。

在动作特征与指令下发方面，本文在标准臂控制模式下将动作空间取为七维关节目标位置，键名与 LeRobot 惯用命名一致，便于与后续策略头维匹配。发送时执行“将一行命令编码并写入套接字—读取应答”的同步原语，并对超时与异常进行日志记录与重连策略预留。

上述设计使弗兰卡平台在 LeRobot 语义下与社区已有从臂等价：同一套录制与回放流程可以迁移使用，仅更换配置文件即可。

2.3.3 带末端夹爪的复合机器人

针对桌面抓取任务，机械臂需配合二指夹爪等末端执行器。本文在夹爪复合配置中将臂部与夹爪作为组合实体建模：观测维度在关节与末端位姿基础上扩展夹爪开合相关量；动作维度在七维关节之外增加归一化到 $[0, 1]$ 的夹爪指令通道。由此，单条时间步上的“状态—动作”对与单一末端执行器语义一致，降低多设备拼接时的字段分叉与后处理成本。

实物侧采用知行 CTAG2F90C 双指平行夹爪（见图 2-2），通过法兰与机械臂末端紧固连接；录制与回放时夹爪开合由示教设备或策略输出的标量通道驱动，并在观测状态中保留反馈量以供闭环诊断。



图 2-2 知行 CTAG2F90C 双指夹爪安装实物

2.4 遥操作方案设计

2.4.1 三维鼠标遥操作

三维鼠标（SpaceMouse 等六自由度输入设备）能够以较高频率输出线性与角增量的组合，操作者通过推拉、旋转鼠标即可在笛卡尔空间表达末端运动意图。本文在 LeRobot 依赖中利用 pypacemouse 库读取设备数据，由独立的读取器线程循环采样，将 USB HID 事件转为统一的增量序列号与数值结构，供上层遥操作类消费。

直接将单次增量映射为关节增量容易导致漂移与抖动。本文实现了位姿累积适配器，在笛卡尔空间维护累积位置向量与累积四元数姿态：对每个采样周期，将设备上报的平移增量按可配置标尺缩放，对平移范数与旋转角施加死区，低于阈值的增量置零；合法增量通过四元数乘法累积到当前姿态，且仅在序列号变化时才更新累积状态，避免同一硬件包被重复积分。

设第 k 次有效采样对应的平移增量为 $\Delta \mathbf{p}_k \in \mathbb{R}^3$ ，姿态增量为单位四元数 $\Delta \mathbf{q}_k$ （采用 (x, y, z, w) 约定），则累积位姿更新可写为

$$\mathbf{p}_{k+1} = \mathbf{p}_k + s \cdot \Delta \mathbf{p}_k, \quad \mathbf{q}_{k+1} = \text{normalize}(\mathbf{q}_k \otimes \Delta \mathbf{q}_k), \quad (2-1)$$

其中 s 为位置缩放系数， $\otimes$ 表示四元数乘法。死区在平移范数与旋转角上已并入 $\Delta \mathbf{p}_k$ 、 $\Delta \mathbf{q}_k$ 的筛选逻辑。

在获得期望腕部位姿后，需通过逆运动学（IK）解算七轴关节目标。本文复用与 VR 遥操作一致的 IK 求解路径，在 C++ 桥接与 Python 包装之间传递参考关节与

目标位姿，对奇异位形与求解失败做异常捕获与日志输出，避免单次 IK 失败中断整条录制会话。

遥操作类继承 LeRobot 的 Teleoperator 基类，实现动作特征声明、连接管理、动作获取等契约：每次获取动作时，将当前鼠标增量经适配器积分后送 IK，输出七维关节目标字典，键名与机器人抽象的动作键一致，从而实现“人通过鼠标在笛卡尔空间表达意图—机器人在关节空间跟随”的闭环。夹爪复合版本在臂部通道上共享同一鼠标读取器，避免对同一 USB 资源双开，夹爪通道则由配置映射为开合标量。

2.4.2 同构主从遥操作

相比三维鼠标等笛卡尔空间设备，同构主从允许示教式关节空间映射：操作者拖动与从臂同自由度数的主臂，从臂实时跟踪，可在关节空间完成贴近台面、绕行障碍等细调。主从几何相似时，操作者对主臂的关节角直觉可迁移到对从臂运动的预期，对抓取流水线中的姿态调整往往更直接。

工程上，主臂与从臂的安装轴向、零点与传动比未必一致，因此必须在软件层引入每关节缩放与偏置，并在夹爪通道引入原始量到 $[0, 1]$ 的线性标定。若缺少系统化标定，示教轨迹在回放时会出现整体偏转、夹爪“开不满/关不严”等问题，直接污染模仿学习数据集。为此，本文采用如下关节空间映射模型：主臂读出的七关节量经缩放与偏置后作为从臂关节指令。设主臂第 i 关节原始读数为 θ_i^L ，经模式函数 $\phi(\cdot)$ 转为主臂侧用于映射的弧度量 $\tilde{q}_i^L$ （例如度模式时 $\tilde{q}_i^L = \text{rad}(\theta_i^L)$ ；规范化模式时 ϕ 为恒等映射并保持与运行时一致）。记缩放系数 α_i 、偏置量 β_i （单位：rad），则从臂指令为

$$q_i^F = \alpha_i \tilde{q}_i^L + \beta_i, \quad i = 1, \dots, 7. \quad (2-2)$$

其中 α 不仅承担比例尺度，更常取 ± 1 以修正轴向反向； β 承担零点对齐。同构主从示教的硬件布置实物如图 2-3 所示：左侧为 Franka FR3 从臂及末端夹爪，右侧为与从臂同自由度数的主臂；操作者拖动主臂各关节，经缩放与偏置后映射为从臂指令。

基于上述映射模型，为使式 (2-2) 中的 α 、 β 及夹爪量程端点可自动解算并版本化，本文设计了两阶段配对标定流程，如图 2-4 所示。

第一阶段为关节对齐，解算偏置向量。操作者与控制员将主臂与从臂摆到同一物理姿态（建议选用重复性高的初始位姿或示教起点）。脚本通过 SoFranka 读取主



图 2-3 同构主从示教硬件布置




图 2-4 两阶段配对标定流程

臂七关节当前值，按运行时计划使用的度/规范化模式转为 q_i^L ；同时提示输入从臂该姿态下的七关节角。缩放向量 α 由命令行指定（七个逗号分隔浮点数，典型为 ± 1 组合），偏置自动修正公式为

$$\beta_i = q_i^F - \alpha_i q_i^L, \quad i = 1, \dots, 7, \quad (2-3)$$

其中 q_i^F 为从臂在该对齐姿态的关节弧度。式 (2-3) 与运行时“先按 α 缩放主臂量、再加 β ”的语义严格一致，从而保证标定与运行时同一解。若主臂工作于度模式而弗兰卡始终以弧度为指令单位，脚本在文档与日志中明确该换算顺序，避免“混用物理单位导致偏置错一个 π ”的常见失误。

第二阶段为夹爪量程，解算开合端点。操作者将主臂夹爪完全闭合与完全张开各一次并在提示时确认；脚本记录两次原始读数，运行时通过线性归一化公式将其映射至 $[0, 1]$ 区间，并在开闭读数接近相等退化情形保留安全截断逻辑。若开闭原始读数方向相反，运行时仍可通过交换端点定义或反向映射保持 0 对应闭合、1 对应张开。

标定脚本支持命令行指定主臂串口、关节读数模式（度制/规范化）、以及单独重标定臂部或夹爪的选项，便于现场迭代。标定结束后以 JSON 统一打印臂部与夹爪字段及注释，可直接进入版本管理，实现“更换主臂/重新固零—重跑脚本—更新配置文件”的闭环。

2.4.3 与录制管线的衔接

两类遥操作方案均实现统一动作获取接口，可与 LeRobot 标准录制流程或自定义循环组合：交替读取机器人观测与遥操作动作，按 LeRobot 数据集模式定义序列化。时间戳对齐上，以机器人状态回执或统一主机时钟为基准，对图像帧与关节指令做最近邻或插值对齐；工程上通过固定控制频率与阻塞读减少抖动，并在元数据中记录相机帧率与伺服周期。

经过配对标定后的主从映射，可显著降低“同一条示教意图”在关节空间的批间方差，有利于小规模高质量轨迹上策略网络的收敛与泛化——该数据规模与后续 $\pi_{0.5}$ 实验章节相对应。

2.5 桌面抓取示教数据采集与 LeRobot 数据集规范


前面各节从工程实现角度完成了机械臂与 LeRobot 的接口打通，并给出了三维鼠标与同构主从两类遥操作方案及其标定流程。本节以实际落地的示教采集流水线为对象，说明采集任务设定、落盘数据如何组织为 LeRobot 官方数据集形态，以及为何该字段编排与多相机布局适合本文的桌面抓取与后续 $\pi_{0.5}$ 类策略训练。

2.5.1 采集任务与录制流程

采集任务设定为：“抓取绿色苹果并放置至桌面左上角”。每条示教轨迹的语言指令单独登记在任务元数据中，全库共 30 条轨迹，在统一任务语义下由操作者通过同构主从臂重复示教完成。

数据录制采用双相机布局：第三人称固定相机获取全局场景信息（桌面目标物位置、放置区域、障碍物等），腕部手眼相机提供夹取局部几何（手指—物体相对关系、闭合接触状态等）。两者以统一的 10 Hz 帧率同步录制。对于桌面抓取这类以准静态接触与柔顺放置为主的操作，该帧率在保证任务相关运动信息不丢失的前提下，降低了存储与解码开销，并与 LeRobot 训练数据加载器的常见假设兼容。

录制流程的整体数据流如图 2-5 所示。



数据采集流程

图 2-5 数据采集流程

2.5.2 LeRobot v2.1 数据集组织

数据集严格遵循 LeRobot v2.1 目录规范，核心由三类路径组成：元数据目录存放全局说明与轨迹列表（机器人类型、总帧数、各字段名称与形状、任务语义与轨迹元信息）；数据目录以列式存储格式（Parquet）按分块存放帧级表格，每文件对应一整条轨迹的时间序列样本；视频目录存放与表格行对齐编码的外挂视频轨道，每个相机、每条轨迹各一条 MP4 视频。

该布局的价值在于：表格存低维时序量（关节角、夹爪开合、末端位姿等），视频存高维图像流，二者通过统一的帧索引与时间戳字段建立一一对应关系；训练代码只需按 LeRobot 的特征声明进行张量拼接，无需定制私有数据加载器。

2.5.3 帧级特征模式

表 2-2 归纳了数据集中声明的主要特征键。动作空间与关节观测在维数与命名上呈对齐关系：均为八维浮点向量，前七维对应弗兰卡七轴关节位置，第八维为夹爪开合通道。这种“状态—动作同构”的写法是行为克隆与扩散策略类方法的常见输入形式：网络在时刻 t 读取多相机图像与本体状态，预测监督目标为同刻示教者给出的关节—夹爪指令或下一时刻目标。

表 2-2 数据集主要帧级特征

特征键	dtype	形状概要	含义（本文设置下）
action	float32	8	示教关节目标 + 夹爪指令，用于监督学习
observation.state	float32	8	关节位置与夹爪反馈，构造策略条件
observation.velocity	float32	7	七轴关节角速度，可选辅助信号
observation.eepose	float32	7	末端位姿 ($x, y, z, q_x, q_y, q_z, q_w$)
observation.images. wrist	视频	720×1280×3	腕部/手眼 RGB，10 fps
observation.images. third_person	视频	720×1280×3	第三人称场景 RGB，10 fps
timestamp 等索引字段	标量	1	帧内时间戳、轨迹/任务编号、全局行号

多相机观测分别以腕部与第三人称两个键挂载。二者在物理视角上互补：第三

人称摄像机提供桌面上苹果目标物、障碍物与边角放置区域的全景关系，适于粗定位与语义对齐；腕部摄像机则提供抓取对准期所需的局部几何与开合过程中的手指—物体相对关系，对降低从侧面观看时的深度歧义至关重要。分辨率 1280×720 、采样率与关节序列一致且视频参数在特征信息块中逐项声明（像素格式、是否具有深度、是否含音频等），保证了跨机器解码的可重复性。

低维本体量除关节状态外，另含七维关节速度与七维末端位姿。前者可用于未来引入速度惩罚或对比学习；后者便于在调试阶段与笛卡尔空间示教设备（如三维鼠标路径）进行交叉验证。对于以关节空间监督为主的 $\pi_{0.5}$ 管线，核心训练张量落在多相机图像与动作（及必要的本体状态）之上，其余字段以“可扩展但不扰动训练接口”的方式存在。

2.5.4 数据规模与质量保障

在规模上，30 条轨迹、合计 5512 帧属于小规模专用数据集，适用于在基础 VLA 模型上进行任务特化微调或概念验证，而不追求覆盖所有桌面扰动。单条轨迹长度在约一百七至一百九十余步之间波动，对应十几秒量级的操作过程，与“抓取—移动—放置”三阶段结构相符。

从数据质量角度，本文在采集端强调三个要点。首先是字段完备性，关键键名符合 LeRobot 约定，减少训练脚本中的硬编码映射。其次是时间一致性，统一 10 Hz 与外挂视频，使视觉与关节标签天然对齐。最后是任务语义显式化，自然语言任务写入元数据并在轨迹信息中重复索引，便于多任务扩展或与语言条件策略对接。在此前提下，即使样本量有限，网络仍主要学习桌面绿色苹果抓取并置于桌面左上区域这一窄分布，与后续章节对 $\pi_{0.5}$ 结构的针对性改进及桌面实验评价形成闭环。

第3章 基于 $\pi_{0.5}$ 的抓取策略训练与实机部署

第二章完成了机械臂与 LeRobot 通用接口的打通（T1）以及桌面抓取示教数据的标准化采集与组织（T2）。本章对应设计任务 T3（ $\pi_{0.5}$ 模型迁移与变体改进）与 T4（实机闭环部署与在线执行策略对比）。设计目标有两个：首先，将 $\pi_{0.5}$ 预训练权重迁移至桌面抓取任务并完成全量微调基线，进而提出冻结骨干与短期记忆两项结构变体以改善小样本条件下的性能与效率；其次，通过受控对比实验量化不同在线闭环策略对同一模型权重在接触敏感任务上的性能影响。具体而言，本章重点说明： $\pi_{0.5}$ 模型^[2]的核心原理与为何其适合迁移到桌面抓取任务；本文如何将双视角观测、八维状态/动作以及自然语言任务提示映射到 OpenPI 训练接口，并基于自采数据集完成微调训练；训练后模型在不同在线执行方式下呈现的显著性能差异，尤其是逐段闭环推理带来的成功率提升；以及结合本文改动与实验观察，对冻结骨干与短期记忆等模型变体的定量对比与行为分析。

需要指出的是，本文的算法贡献并非简单复现已有 $\pi_{0.5}$ 结果，而是将其从原论文面向移动双臂家庭机器人、长时程多阶段任务的设定，迁移到静态桌面抓取这一更聚焦但接触精度要求更高的场景中。为此，本文完成了数据接口重构、训练配置适配、在线执行闭环设计与行为层面的现象分析，从而形成“硬件接入-示教采集-策略训练-实机部署”的完整毕业设计闭环。

3.1 $\pi_{0.5}$ 的核心原理框架

3.1.1 从 VLA 到分层推理

视觉-语言-动作模型（Vision-Language-Action, VLA）试图直接学习从观测与语言指令到机器人动作的映射。对单步或动作块预测而言，其基本目标可写为

$$\max_{\theta} \mathbb{E}_{(\mathbf{a}_{t:t+H}, o_t, \ell) \sim \mathcal{D}} \log \pi_{\theta}(\mathbf{a}_{t:t+H} \mid o_t, \ell), \quad (3-1)$$

其中 o_t 包含时刻 t 的多相机图像与机器人本体状态， ℓ 为自然语言任务指令， $\mathbf{a}_{t:t+H}$ 表示长度为 H 的动作块。与传统仅依赖低维状态的行为克隆不同，VLA 同时利用视觉与语言信息，使策略具备更强的任务条件表达能力与跨对象泛化潜力^[1]。

$\pi_{0.5}$ 的关键思想在于：将高层语义推理与低层动作生成统一到同一个多模态序

列建模框架中，而不是单纯把“图像 + 文本”直接映射为动作。传统的端到端模仿学习策略往往直接输出控制量，虽然在单一任务上可以工作，但一旦任务中包含“先观察目标、再对准、再夹取、再搬运”的多阶段结构，纯低层策略往往难以显式表达当前子目标。 $\pi_{0.5}$ 试图解决的正是这一问题：它既保持了 VLA 对视觉和语言的理解能力，又把“当前应该做什么”编码成显式语义中间层，使动作生成不再完全依赖隐式内部状态。

原论文将模型分解为高层子任务推断与低层动作预测两部分，其联合分布可写为

$$\pi_{\theta}(\mathbf{a}_{t:t+H}, \hat{\ell} \mid o_t, \ell) = \pi_{\theta}(\hat{\ell} \mid o_t, \ell) \pi_{\theta}(\mathbf{a}_{t:t+H} \mid o_t, \hat{\ell}), \quad (3-2)$$

其中 $\hat{\ell}$ 表示模型根据当前场景与高层任务自动生成的语义子任务，例如“抓住苹果”“移动到桌面左上角”等。该结构的意义在于：模型可以先决定“当前最适合做什么”，再决定“具体如何做”，从而把长时程任务分解成若干更稳定的局部动作过程。这种思路与语言模型中的链式推理存在相似性，但 $\pi_{0.5}$ 将其落到了机器人可执行的动作闭环中^[2]。从控制角度看，式 (3-2) 也意味着模型把任务分解误差与动作跟踪误差在建模层面分离开来：高层语义负责减少“做错事”的风险，低层动作负责减少“做不准”的风险。

对于本文的桌面苹果抓取任务，虽然任务长度远短于原论文中的“整理厨房”“铺床”等家庭长任务，但接近目标、夹取接触、抬升确认、放置到指定区域依然天然构成了一个多阶段操作链。因此， $\pi_{0.5}$ 的分层思想依旧具有价值：高层语义可帮助策略在“寻找目标-对准抓取-完成搬运”之间切换，而低层动作块则负责生成连续、可执行的关节与夹爪指令。特别是在苹果这类易滚动、易滑动物体的抓取中，若没有对子目标的良好组织，低层策略很容易把“接近目标”和“稳定夹持”混为一个不可分的黑盒过程，导致接触阶段误差被快速放大。

3.1.2 统一多模态序列建模

$\pi_{0.5}$ 的第二个关键点，是它并没有为“看图”“理解语言”“预测子任务”“输出动作”分别设计彼此割裂的模型，而是试图把这些信息都放到一个统一的序列建模框架中。其底层做法是：将图像 patch、文本 token、机器人本体状态以及动作相关表示映射到同一 Transformer 中，通过注意力机制建立跨模态关联。这样一来，模型在

看到第三人称图像中的苹果、腕部相机中的夹爪位置以及文本提示“抓取苹果并放到左上角”时，可以在统一特征空间里决定当前最相关的信息组合。

从模型设计看， $\pi_{0.5}$ 并不是简单把所有 token 串在一起做标准因果注意力，而是使用了前缀-后缀式的注意力组织。图像、语言提示以及部分状态信息作为前缀，允许在前缀内部进行充分的信息交互；动作相关 token 则作为后缀，在访问前缀条件信息的同时保持适合动作生成的依赖结构。这样的设计有两个直接好处：一方面，动作生成不再只依赖某一个单独编码后的观测向量，而是依赖整个多模态上下文序列，充分利用视觉语义上下文；另一方面，同一个主干既可以输出文本型子任务，也可以为后续动作专家提供条件特征，便于统一高层与低层推理。

对本文任务而言，这种统一建模尤其重要。由于桌面抓取同时依赖全局视角与局部手眼视角，如果采用两套完全分离的感知链路，系统往往会面临信息对齐复杂、训练目标割裂的问题。而在 $\pi_{0.5}$ 框架中，第三人称图像更偏向提供目标位置和放置区域的全局语义，腕部图像更偏向提供夹取局部几何与接触反馈，两者都被放入同一个条件上下文中，因此更适合学习“先粗定位、再精对准”的策略模式。

3.1.3 主干网络与动作专家

在结构上， $\pi_{0.5}$ 建立在 π_0 ^[1] 之上，延续了“视觉语言主干 + 动作专家（action expert）”的设计。主干部分继承预训练视觉语言模型的表征能力，其核心由 SigLIP 视觉编码器和 Gemma 语言模型骨干组成；图像被切分为 patch token，自然语言指令被编码为文本 token，而机器人状态与动作则通过专门的投影与编码方式进入同一 Transformer 序列中^[28]。这样做的本质，是把机器人控制问题转化为统一的多模态序列建模问题。

与纯文本自回归模型不同，机器人策略不仅要输出语义 token，还要输出连续动作。为此， $\pi_{0.5}$ 在主干之外引入更小的动作专家模块，对动作块进行专门建模。动作专家的作用可以概括为两点。首先，主干网络保留语言与视觉理解能力，动作专家则专注于生成高精度、低时延的连续控制量，实现语义推理与连续控制的分离；其次，若直接以离散动作 token 自回归逐个采样，实机部署时延较大，动作专家将动作块视为连续变量分布，能以更少的推理步数生成整个动作序列，提高在线推理效率。

相比之下， $\pi_{0.5}$ 相对于 π_0 有两处重要改变。首先，机器人状态可以作为离散语言 token 的一部分输入，而非仅作为连续后缀输入；其次，在动作专家中使用自适应

归一化（adaRMSNorm）的方式注入 flow matching 时间步，使每一层动作专家都能感知当前的去噪阶段。本文在训练配置中启用了上述路径，确保模型结构接近论文原意的 $\pi_{0.5}$ 设计。

3.1.4 动作专家中的 Flow Matching 机制

动作专家与 flow matching 的结合，是 Pi 系列模型区别于许多传统 VLA 的核心创新之一。其出发点在于：离散 token 对大规模预训练很友好，但真实机器人控制需要的是连续、平滑、低延迟的动作输出；如果完全依靠离散动作 token 自回归采样，不仅推理速度受限，而且连续控制精度也可能受动作量化误差影响。Pi 系列的关键设计，就是在保留大模型主干语义能力的同时，用一个更小、更专门化的动作专家来建模连续动作分布^[1-2]。

设真实动作块为 $\mathbf{a}_{t:t+H}$ ，噪声为 $\boldsymbol{\omega} \sim \mathcal{N}(0, I)$ ，时间变量为 $\tau \in [0, 1]$ ，则 flow matching 中的中间变量可写为

$$\mathbf{x}_\tau = \tau \boldsymbol{\omega} + (1 - \tau) \mathbf{a}_{t:t+H}. \quad (3-3)$$

其直观含义是：当 τ 接近 1 时， $\mathbf{x}_\tau$ 更接近纯噪声；当 τ 接近 0 时， $\mathbf{x}_\tau$ 更接近真实动作。动作专家并不直接回归最终动作，而是学习一个向量场，把当前的噪声化动作逐步“拉回”到真实动作块所在的分布流形上。若记目标向量场为

$$\mathbf{u}_\tau = \boldsymbol{\omega} - \mathbf{a}_{t:t+H}, \quad (3-4)$$

则模型的任务可以理解为：在给定观测条件 o_t 、任务提示 ℓ 以及当前中间状态 $\mathbf{x}_\tau$ 的情况下，预测一个足以将当前样本推向真实动作的连续更新方向。

这种设计相比直接回归动作块，具有三方面优势。第一，表达能力更强。对于多峰或接触敏感的动作分布，直接回归往往倾向于输出平均动作，而 flow matching 更适合刻画连续动作分布的形状。第二，推理效率更高。模型不需要逐 token 自回归采样完整动作序列，而是通过少量迭代积分生成整段动作。第三，与大模型主干天然解耦。动作专家可以比主干小很多，只负责连续控制这一件事，因此既保留了主干的视觉语言能力，又避免把所有控制负担都压到超大参数主干上。

Pi 系列的一个关键工程点是如何将时间步 τ 注入动作专家。 π_0 主要通过将时间信息与动作 token 混合后再输入动作分支；而 $\pi_{0.5}$ 更进一步，采用自适应归一化的方

式注入时间条件：独立的时间多层感知机（MLP）生成时间嵌入，作为每一层动作专家自适应 RMS 归一化的条件输入，而非简单拼接到动作 token 后。这一设计使时间步信息对整条去噪轨迹的调制更加稳定，也更符合“动作专家专门负责连续流场生成”的定位。

从本文桌面抓取任务看，flow matching 的价值尤其体现在接近-闭合-抬升这类短时连续接触动作中。若动作输出过于离散，夹爪闭合时机、抬升速度和末端姿态变化都容易产生不连贯现象；而 flow matching 生成的连续动作块更容易保持轨迹平滑。进一步结合本文后续的分段闭环执行策略，可以把这种连续动作块理解为“局部时间窗内的平滑控制建议”，再通过频繁重推理不断修正，从而兼顾了平滑性与反馈性。

3.1.5 离散动作预训练与连续动作后训练

$\pi_{0.5}$ 训练流程的第二个核心，是离散动作表示与连续动作表示的结合。原论文在预训练阶段使用 FAST 动作离散化^[26]，将动作块编码为离散 token，从而能够用标准自回归 next-token prediction 的方式大规模高效训练；而在后训练阶段，则引入 flow matching^[29] 风格的连续动作生成机制，以获得更适合实时控制的连续输出。更具体地说， $\pi_{0.5}$ 不是在预训练阶段就完全依赖连续动作建模，而是先利用离散动作 token 获得高效、稳定的大规模训练，再在后训练阶段加入动作专家与连续动作目标。这样做的原因是：离散 token 训练与大模型生态更加兼容，便于复用已有视觉语言主干；而连续动作建模则更适合最终实机部署。原论文形式化地将总目标写成文本交叉熵损失与连续动作场回归损失的加权和^[2]。对本文而言，这一机制的意义在于：训练阶段能够继承预训练 VLM 在语义与视觉上的能力；部署阶段能够直接输出连续关节/夹爪动作块，避免全自回归动作采样导致的时延；此外，通过动作块预测，使控制器在短时域内保持动作连续性与平滑性。

3.1.6 异构数据协同训练的意义

$\pi_{0.5}$ 之所以区别于传统桌面行为克隆策略，不只因为模型结构更大，更重要的是其协同训练（co-training）思想。原论文并不是只用目标机器人自己的示教数据训练策略，而是把多种来源的数据放进同一个训练食谱中，包括：不同机器人本体的数据、跨场景的数据、高层语义子任务标注、网页图文数据以及目标平台上的后训练数据^[2]。这种思路的直接收益是：即便目标场景上的机器人数据规模有限，模型依然

可以从外部多模态知识中继承对象识别、语言对齐与任务分解能力。

本文的桌面抓取实验仅使用了 30 条自采轨迹，规模远小于原论文数百小时级别的数据量，因此更能体现 $\pi_{0.5}$ 这种“先借助大模型与异构数据获得通用能力，再用小规模专用数据做任务特化”的价值。针对小样本、接触敏感的桌面任务特性，本文提出了冻结视觉语言骨干与短期记忆两项模型结构改进，其原理与实现详见第四章。

3.2 面向桌面抓取的模型适配与训练实现

3.2.1 任务观测与动作空间重定义

原始 $\pi_{0.5}$ 论文面向带移动底盘、升降机构与双臂夹爪的家庭服务机器人，其状态与动作空间维数达到 18 ~ 19 维，且在高层推理时会使用四路相机，在低层动作推理时使用前向相机与双腕相机^[2]。本文场景则聚焦于静态单臂桌面抓取，其控制对象与观测形式更紧凑，因而必须进行接口层与数据层的重新定义。

本文在训练配置中将数据重排为如下结构：图像输入将第三人称相机映射为全局视角（base）、腕部相机映射为手眼视角（wrist），状态输入使用 `observation.state` 作为低维本体状态，动作监督使用 `action` 作为策略目标，语言提示使用数据集中的任务描述作为文本输入。

结合第二章的数据集定义可知，本文任务中的 `state` 与 `action` 均为八维向量：前七维对应弗兰卡七轴关节，第八维对应夹爪开合量。这样一来，本文的动作空间既保留了夹取任务所需的末端开合信息，又避免了在小数据场景下额外建模底盘与多臂协调，从而使训练重点聚焦到“桌面目标定位、抓取对准、夹紧抬升与搬运放置”这几个关键环节。

这种改写的价值在于：虽然本文采用的是 $\pi_{0.5}$ 的总体思路，但并未机械照搬原论文的机器人输入格式，而是将观测-动作接口完全纳入 OpenPI 可消费的通用数据范式。这正是第二章工作的算法侧落点：没有前面的接口统一与数据规范化，就无法把原本服务于通用机器人 VLA 的训练框架直接用于本平台实机任务。

3.2.2 训练配置与关键超参数

表 3-1 汇总了本文桌面苹果抓取任务的主要训练设置。训练配置整体遵循“加载 $\pi_{0.5}$ 基础权重，在本地数据集上进行任务微调”的思路，既保留了原模型动作块预测的优点，也针对桌面任务做了更紧凑的时域设置。

表 3-1 苹果抓取训练配置

配置项	取值与说明
模型类型	$\pi_{0.5}$ （动作块长度 32，最大 token 长度 200）
数据集	自采桌面抓取数据集，本地加载
图像映射	第三人称相机 → 全局视角，腕部 → 手眼视角
状态 / 动作	8 维关节与夹爪状态 / 8 维关节与夹爪动作
语言提示	数据集任务描述字段
预训练权重	加载 $\pi_{0.5}$ 基础权重
归一化统计量	复用预训练资产中的归一化参数
批大小	4
数据加载线程数	2
训练步数	50,000
模型保存间隔	每 10,000 步

其中有三项设置需要重点提及。

在时域设置上，本文将动作块长度设为 32。与原论文更长的动作视界相比，更短的动作块有利于减少单次预测覆盖的开环时间，降低接触误差积累，同时在后续部署中更容易结合“执行一部分动作后重新观测再推理”的策略。

在序列容量上，最大 token 长度设为 200。虽然本文任务文本提示较短，但由于 $\pi_{0.5}$ 会把状态与多模态条件统一编码到序列中，保留较大的 token 容量可避免在迁移过程中因输入裁剪而损失条件信息。

在参数初始化上，训练配置加载已有的 $\pi_{0.5}$ 基础权重，再结合本文任务数据进行继续训练。对于仅有 30 条示教数据的小规模数据集而言，这是获得可用性能的关键前提：视觉主干与语言主干提供通用感知能力，动作专家与相关层在任务数据上完成针对性调整。

3.2.3 本文对 $\pi_{0.5}$ 的适配工作

本文对 $\pi_{0.5}$ 的工作并非简单的“换数据训练”，而是围绕桌面抓取场景完成了四个层面的针对性适配。

首先是平台适配。将单臂与二指夹爪的八维状态/动作与 LeRobot 标准数据集字段对齐，再进一步映射到 OpenPI 的多模态输入接口，使训练框架可直接消费第二章构建的数据集。

其次是观测适配。从原始移动机器人多相机设定收缩到“第三人称 + 腕部相机”

的双视角组合，保留对目标定位和精细接触都最关键的视觉信息，同时降低输入维度的冗余。

再次是部署适配。不直接照搬整段动作块开环执行，而是针对真实接触任务设计了更紧凑的”短时执行 + 重观测重推理”闭环策略（详见第3.3节），大幅提升接触敏感阶段的在线修正能力。

最后是评估适配。将原论文面向开放家庭场景的泛化指标转换为本文任务更关心的抓取成功率、掉落/滑落现象以及失败后的再搜索能力，形成可定量对比的实验基准。

3.3 在线推理执行策略与实机效果分析

3.3.1 两种部署方式的差异

训练完成后，本文分别使用异步远端推理与分段同步闭环两种部署方式进行实机测试。两者都通过 WebSocket 与 OpenPI 远端推理服务通信，并向机械臂发送关节与夹爪指令，但其控制闭环方式明显不同。

异步远端推理采用推理线程与控制线程解耦的方式：推理线程不断发送最新观测并获取新的动作块，控制线程则以固定频率执行“当前最新的有效动作”。如果某些动作在推理返回时已经过期则直接丢弃。这种设计在理论上可以提高系统利用率，但也意味着机器人在执行阶段可能使用的是一段并非基于最新视觉反馈重新规划得到的动作序列，执行偏长时开环。

分段同步闭环则采用截然不同的方式：每次先读取一次机器人观测，推理得到一整个动作块后，仅截取其中一小段（约 8 步）执行，执行完成后立刻重新读取新观测并再次推理。若系统控制频率取 30 Hz，则一次执行窗口大约只覆盖

$$\Delta t \approx \frac{8}{30} \text{ s} \approx 0.27 \text{ s}, \quad (3-5)$$

这使得策略以“短时开环 + 高频重规划”的方式运行。虽然总推理次数增多，但它显著增强了接触任务中的在线修正能力。

3.3.2 成功率差异的原因分析

本文实验中最突出的现象是：采用异步远端推理时，抓取成功率仅约为 5%；而改用分段同步闭环后，成功率大幅提升，接近 100%。二者使用的是同一个训练后的

表 3-2 两种部署方式对比

部署方式	控制方式	典型行为特征	实验现象
异步远端推理	异步推理 + 固定频率执行最新动作块	动作可能在返回时部分过期，执行更偏开环	成功率很低，约 5%，苹果常滑走
分段同步闭环	同步分段推理，每次只执行动作块的一小段	高频“观测-执行-再观测-再执行”闭环	成功率接近 100%，抓取稳定显著提升

模型，因此这一差异主要不是由模型参数本身导致，而是由在线闭环方式决定的。

结合任务过程，可以将原因概括为以下三点。


首先，桌面抓取是强接触敏感任务，不能长时间开环。苹果表面光滑、受力后易滚动或侧滑，机械臂在接近苹果、闭合夹爪以及抬升初期这几个阶段，对末端相对位姿误差极为敏感。若模型依据稍早的观测生成一整段动作，而环境在执行中已经发生细小变化（例如苹果被碰动、夹爪接触点偏移），则后续尚未执行完的动作就会迅速失效。异步方式虽然也会丢弃明显过期动作，但本质上仍倾向于执行一段较长的开环计划，因此容易出现“看起来已经接近苹果，但夹取瞬间发生滑移”的现象。

其次，分段执行将动作块预测转化为滚动时域控制。分段同步闭环并不一次执行完整动作块，而是只截取其中一小段执行，然后立即重新获取观测并调用策略。模型始终在最近一次观测的条件下生成接下来的局部动作，因此能够及时修正末端位置、夹爪开合时机以及抬升方向。对于抓取任务来说，这比单纯追求动作连续更重要。

最后，闭环重推理显著提升了失败恢复能力。桌面抓取中的错误并不总是彻底失败，更多表现为局部偏差，例如夹爪没有完全包住苹果、闭合时苹果稍微滑出、抬升初期苹果从夹爪边缘滚落等。同步分段推理使模型能在极短时间内再次观察当前状态，并重新决定是继续抬升、重新对准，还是回退再抓。因此，它不仅提高了首次抓取的成功率，也增强了局部失败后的再恢复能力。

3.3.3 实验现象与任务完成质量

从实验现象看，两种部署方式在接近目标与搬运路径平滑性方面都表现出较好的运动质量，说明训练得到的策略确实学习到了较稳定的桌面抓取动作模式；差异主要集中在抓取接触瞬间及其后的短时稳定保持阶段。采用异步部署时，机械臂通常能够移动到苹果附近，但夹爪闭合与抬升的配合不够及时，苹果常在指尖边缘滑

图 3-1 $\pi_{0.5}$ 实机抓取过程快照

走，导致任务在最后一步失败。采用分段闭环部署后，模型可以在每小段执行后重新观察苹果与夹爪的相对位置，因此显著降低了这种接触阶段的误差放大。

这一结果说明，对使用动作块输出的 VLA 而言，部署策略本身与模型结构同样重要。即使训练得到的动作块质量较高，若部署阶段仍以偏开环的方式执行较长动作序列，实机接触任务也可能出现明显性能下降；而将动作块推理嵌入更紧的闭环中，往往能够释放模型已有的感知-控制能力。这一结论对于今后将 VLA 部署到高精度桌面装配、插接、对准等任务中也具有普遍意义。

图 3-1 给出微调后 $\pi_{0.5}$ 策略在实机在线推理条件下由第三人称相机记录的一组离散画面。各子图按执行轨迹导出帧序号 0-8 排列（自上而下、从左至右），对应同一桌面苹果抓取任务语义下模型闭环执行过程中的若干代表性时刻：帧 0 到 90 为接近与夹取阶段，帧 90 到 180 为抬升与搬运阶段，帧 180 到 270 为放置与回撤阶段。与第二章人工示教录制的轨迹不同，此处轨迹完全来自 VLA 根据多相机观测与语言条件逐步推理得到的动作块经实时控制服务执行后的结果；阶段边界会因推理节拍、动作块截取策略与采样间隔而与连续时间轴略有错位，亦可与腕部视角录像及关节

一夹爪时序曲线交叉核对。

3.4 全量微调基线性能

在完成训练配置与部署方式对比后，本文以全量微调版本的 $\pi_{0.5}$ 作为实验基线进行定量评估。该版本在加载 $\pi_{0.5}$ 预训练权重的基础上，对全部参数进行任务特化微调。在采用分段闭环部署（第3.3节）的条件下，基线模型在 10 次实机抓取测试中成功 8 次，成功率约为 80%，推理显存占用约为 12 GB，全量微调训练显存约为 160 GB（批次大小为 4）。

全量微调基线的优势在于表达能力完整、上下文利用充分；但其局限性同样明显：数十亿参数的充分更新对仅有 30 条示教轨迹的小样本量而言存在过拟合风险，且不加约束地更新视觉语言骨干可能破坏预训练中积累的语义先验，反而损害泛化性能。针对这些不足，本文进一步提出了冻结骨干与短期记忆两项结构改进，其原理设计、实现细节与实验分析详见第四章。

第 4 章 $\pi_{0.5}$ 模型结构改进

第三章阐述了 $\pi_{0.5}$ 的通用架构原理及其在桌面抓取任务上的训练与部署流程。然而，全量微调基线并非针对本任务的最优方案：30 条示教轨迹的小样本量难以支撑数十亿参数的充分更新，且桌面抓取固有的接触敏感、短周期闭环特性对模型的在线响应速度提出了更高要求。本章针对这两个瓶颈，提出并深入阐述两项结构改进。第一项是基于参数路径过滤的冻结骨干机制，在不修改模型代码的前提下将训练显存占用由约 160 GB 降至约 60 GB（批次大小为 4）并提升成功率；第二项是基于空间-时间可分离注意力的短期记忆变体，在视觉编码器中通过因果时间注意力与历史 token 压缩机制，为模型提供短期视觉记忆，使模型自发涌现失败恢复能力。两项改进通过配置驱动设计，体现了“针对性结构约束优于无条件保留全部模型能力”的方法论原则。

4.1 基于参数路径过滤的冻结骨干机制

4.1.1 问题分析：小样本全量微调的风险

$\pi_{0.5}$ 的完整参数空间可划分为三个主要部分：SigLIP 视觉编码器、以 Gemma 2B 为核心的 VLM 语言骨干（在参数树中记为 `llm`）、以及 Gemma 300M 动作专家（记为 `llm_1`），此外还有少量投影层与时间嵌入 MLP 等辅助模块。全量微调基线不加区分地对所有参数计算梯度并更新，这在仅有 30 条示教轨迹的条件下存在两个风险：一是数十亿参数的充分更新远超出小样本的承载能力，容易引发过拟合；二是不加约束地更新视觉语言骨干可能破坏其在预训练中积累的语义先验（如物体识别、空间关系理解等），反而损害策略的泛化性能。

4.1.2 OpenPI 框架的参数冻结基础设施

OpenPI 训练框架提供了一套基于正则表达式路径匹配的参数冻结机制，核心由两个组件构成：冻结过滤器生成方法（定义于模型配置模块）和训练入口中的可训练过滤器逻辑。

`get_freeze_filter()` 通过以下过滤器组合来标识需冻结的参数集合：

`PathRegex(".*llm.*")`：匹配参数路径中所有包含 `llm` 的项，覆盖 VLM 骨干（`llm`）和动作专家（`llm_1`）；

`PathRegex('.*llm.*_1.*')`: 精确匹配动作专家参数，用于将 `llm_1` 从冻结集合中排除。

该方法的组合逻辑设计为：当调用配置的 `paligemma_variant` 字段含有子串“lora”而 `action_expert_variant` 不含该子串时，生成

$$\text{All}(\text{PathRegex}(. * \text{llm} .*), \text{Not}(\text{PathRegex}(. * \text{llm} .* _1 .*))). \quad (4-1)$$

式 (4-1) 的含义是：冻结所有匹配 `.*llm.*` 的参数，再从中排除属于动作专家 `llm_1` 的部分。最终效果是精确冻结 PaliGemma 视觉语言骨干，而 Gemma 300M 动作专家、时间 MLP 及各类投影层保持可训练。需要注意，此处传入的 `PiOConfig` 仅用于生成过滤器，实际模型的变体配置由主训练配置中的 `model` 字段独立指定，因此模型的参数树中并不包含 LoRA 层。

在训练执行侧，`TrainConfig` 的 `trainable_filter` 属性自动计算为

$$\text{trainable_filter} = \text{All}(\text{Param}, \text{Not}(\text{freeze_filter})), \quad (4-2)$$

即全体参数与冻结过滤器的差集。在 JAX 训练步 `train_step` 中，梯度传播被显式限定在可训练子集上：

$$\text{diff_state} = \text{DiffState}(\mathbf{0}, \text{trainable_filter}), \quad (4-3)$$

其中 `DiffState` 的第一个参数为初始梯度值（零向量），第二个参数指定哪些参数的梯度需要被追踪。式 (4-2) 和 (4-3) 共同保证：被冻结的参数在前向传播中正常参与计算、提供预训练表征，但在反向传播中完全不被求导、不被优化器更新、对应的优化器状态也不被分配显存。这正是冻结骨干后训练显存占用从约 160 GB 降至约 60 GB（批次大小为 4）的底层原因。

4.1.3 配置实现与实验效果

在具体配置层面，仅需在训练配置中为冻结过滤器指定 VLM 骨干类型与动作专家类型（Gemma 300M），即可生成式 (4-1) 所示的过滤器，其余所有配置（数据、优化器、训练步数）保持不变。从全量微调切换为冻结骨干模式仅需一行配置，这种设计使不同模型变体的对比实验可以在严格控制其他变量的条件下进行。图 4-1 直观对比了两种训练模式下参数更新范围的差异。




图 4-1 全量微调与冻结骨干训练模式对比

在补充实验中，冻结骨干变体在 10 次实机苹果抓取测试中成功 9 次（成功率 90%），较全量微调基线（80%，见第三章第3.4节）提升 10 个百分点；同时训练显存占用从约 160 GB 降至约 60 GB（批次大小为 4）。成功率提升验证了小样本条件下保留预训练视觉语义先验比充分更新全部参数更有利的判断；训练显存的大幅下降显著降低了对计算设备的要求。

4.2 短期记忆变体

4.2.1 问题分析：单帧视觉编码在桌面抓取中的局限

当前 $\pi_{0.5}$ 的视觉前缀采用“按相机逐帧编码、直接拼接”的方式：每个相机的当前帧经 SigLIP 编码为 patch tokens 后，直接与语言 token 拼接入 Gemma 主干。这种设计没有显式建模时间维度——模型在每次推理时只能“看到”当前时刻的一帧图像，完全不具备对过去数秒视觉观测的记忆能力。

对于桌面苹果抓取任务，缺乏短期视觉记忆带来的问题尤为突出：夹爪接近目标时若短暂遮挡苹果、闭合夹爪瞬间苹果发生滚动或滑移、抬升初期夹爪从边缘脱落——这些情况下，模型若能记住“片刻前苹果的确切位置”或“夹爪刚接触苹果时的相对位姿”，便更有能力生成修正动作。然而，如果沿用当前设计把过去 K 帧逐帧过一次 SigLIP 再全部拼给 Gemma，每个相机的 token 数将乘以 K ，LLM 前缀长度、prefix attention 与 KV cache 体积线性增长，推理延迟和显存占用会快速失控。

这正是 MEM 论文 C 部分要解决的核心问题：如何在视觉编码阶段就对历史帧

进行压缩融合，而非把所有历史 token 都扔给 VLM 主干。

4.2.2 MEM 式短期记忆视频编码器的核心原理

MEM 论文^[34]提出的短期记忆模块，并非简单增加历史帧数量，而是在视觉编码器（SigLIP/ViT）内部引入时间维度建模，通过空间-时间可分离注意力（Space-Time Separable Attention）在保留当前帧空间细节的同时，以极低的 token 开销压缩历史视觉信息。其核心机制包括以下三个层面。

(1) 时间位置编码与预训练权重对齐。

对第 l 层、空间 patch p 、时间步 t 的输入 token $z_{p,t}^{l-1}$ ，加入仅依赖时间步的正弦位置编码：

$$\hat{z}_{p,t}^{l-1} = z_{p,t}^{l-1} + e(t), \quad (4-4)$$

其中 $e(t)$ 为 sinusoidal embedding，且强制满足边界条件 $e(0) = 0$ 。这一条件使得“当前帧”（ $t = 0$ ）的表示与原单帧 SigLIP 编码完全一致，从而最大限度地继承预训练 ViT 的视觉能力。

(2) 空间-时间可分离注意力。

论文将视频注意力分解为两步可分离操作——先做时间方向注意力，再做空间方向注意力：

$$\alpha_{p,t}^{l,a}(S = \{1, \dots, N\}, T = \emptyset) \left[\alpha_{p,t}^{l,a}(S = \emptyset, T = \{1, \dots, T\})[\hat{z}] \right], \quad (4-5)$$

其中 S 和 T 分别表示空间和时间索引集合。工程上，时间注意力（因果）对同一 patch 位置 p 沿时间轴做因果 attention（ $t' \leq t$ ），确保训练时不泄漏未来帧信息；空间注意力（双向）对同一时间步 t 在所有 N 个 patch 上做标准双向 attention。

Q/K/V 投影矩阵直接复用原始 SigLIP 每层每头的参数，视频化主要发生在注意力连接方式的改变上，而非彻底重训新主干。实现上通过张量形状变换即可复用现有多头注意力：时间注意力将 token 序列重塑为 $(B \times N, K, D)$ 后在 K 个时间步上做因果注意力，空间注意力将 token 序列重塑为 $(B \times K, N, D)$ 后在 N 个图块上做双向注意力。

(3) 历史 token 压缩：当前帧全量 + 历史帧池化摘要。

论文正文图 4 与附录 C 还强调了 token 压缩策略——在较高层逐步丢弃过去时

间步的 observation tokens，只保留更少、更抽象的历史 token 传给 VLM 主干。本文采用“当前帧保留全部 N 个 patch tokens + 每个历史帧仅保留 M 个池化摘要 tokens ($M \ll N$)”的策略，通过可学习的 pooling 将过去帧压缩为少量 memory tokens。

4.2.3 本文实现与关键参数

本文在 OpenPI/ $\pi_{0.5}$ 框架中新增了视频编码模块，在 SigLIP 的图块嵌入与空间注意力层权重基础上，增加时间位置编码与空间-时间可分离注意力，最终输出压缩后的视觉记忆 tokens 供前缀构造使用。该模块的关键配置参数如表 4-1 所示，其工作原理如图 4-2 所示。

表 4-1 短期记忆模块关键配置

参数	取值	含义
记忆窗口帧数	4	模型可访问最近约 0.4–0.5 秒内的视觉历史
历史帧采样间隔	1（控制步）	连续帧无跳帧，保证时序连续性
每历史帧保留的池化摘要 token 数	8	相较单帧约 256 个 patch token 实现约 32 倍压缩
当前帧保留策略	全部 patch tokens	保证抓取接触阶段的细粒度空间精度
施加时间注意力的层数	4	在 SigLIP 的若干中间层施加因果时间注意力
启用短期记忆的相机	腕部相机	遮挡恢复和抓取修正主要依赖腕部手眼视角

其中，4 帧记忆窗口与帧间隔为 1 意味着模型能访问最近约 0.4–0.5 秒内的视觉历史；每历史帧仅保留 8 个池化 token，相较单帧约 256 个 patch token 实现了约 32 倍压缩；当前帧保留全部 patch token 以保证抓取接触阶段的细粒度空间精度。初始版本仅对腕部相机启用短期记忆，因为遮挡恢复和抓取修正主要依赖腕部手眼视角的局部几何信息。

前缀拼接后结构为：

$$\underbrace{[\text{cam}_{\text{wrist}} \text{ 当前帧 tokens} + \text{历史摘要 tokens}]}_{\text{视频记忆编码器输出}} + [\text{cam}_{\text{base}} \text{ 当前帧 tokens}] + [\text{prompt tokens}], \quad (4-6)$$

其中视频记忆编码器输出的历史摘要 tokens 远少于将原始 K 帧全部展开的 token 数，




图 4-2 短期记忆视频编码器工作原理

从而在不显著增加 LLM 前缀长度的前提下为模型提供短期视觉记忆。

4.2.4 行为效应与实验验证

从行为层面看，短期记忆视频编码器带来了三个方面的提升。一是增强遮挡鲁棒性：当夹爪短暂遮挡目标苹果时，模型可通过历史帧中未被遮挡的苹果位置信息继续引导末端接近，而非在失去目标视觉后立即进入随机搜索。二是改善接触阶段修正能力：夹取瞬间若苹果发生滑移或滚动，历史帧中记录的位置变化使模型能够感知位移方向并生成相应的末端调整动作。三是自然形成失败恢复能力：一旦初次夹取失败（如苹果从指尖滑落），近期的视觉记忆使模型仍能定位苹果的当前位置，自主生成“重新搜索-对准-夹取”的恢复动作序列，而非在失败轨迹上继续执行无效动作。

尤为重要的是，短期记忆变体并未引入显式的失败检测模块、额外的重试逻辑或人工设计的恢复轨迹。这种自发失败恢复能力的涌现，完全来自视觉编码器对近期视觉历史的压缩融合——模型在条件输入层面就获得了对“刚才发生了什么”的感知。在补充实验中，短期记忆变体在 10 次实机测试中成功 10 次（100%），并在多次初次夹取失败后自主完成了再搜索与再夹取。

从更宏观的视角看，短期记忆变体的有效性揭示了一个对桌面 VLA 部署具有普遍意义的洞察：对于接触富集、短周期闭环主导的任务，在视觉编码阶段而非 LLM 前缀阶段压缩历史信息，能够以更低的计算代价获得更强的在线修正能力。这一发

现与第 3.3 节中分段闭环执行策略的成功率提升（从约 5% 至接近 100%）形成互补——前者从模型结构层面增强了对近期视觉信息的利用效率，后者从部署策略层面确保了推理结果能够及时响应最新观测。

4.3 模型变体综合对比与启示

表 4-2 对本文三类模型变体的实验效果做了归纳对比。

表 4-2 模型变体效果对比

模型变体	结论性质	主要特点	预期/观察效果
基础版 $\pi_{0.5}$ 微调模型	已观察	能力完整，适合作为主基线	10 次抓取成功 8 次，成功率约 80%；训练显存约 160 GB，推理显存约 12 GB
冻结视觉语言主干，仅调动作专家	已观察	训练代价低，保留原始语义先验	10 次抓取成功 9 次，成功率约 90%；训练显存约 60 GB，推理显存约 12 GB
冻结视觉编码器，微调其余模块	预估	适合固定视角、固定对象类别场景	可能在小数据条件下取得较好的精度/成本折中
短期记忆 $\pi_{0.5}$	已观察 + 机理分析	视觉编码器中引入空间-时间可分离注意力与历史 token 压缩，提供短期视觉记忆	10 次抓取成功 10 次，成功率 100%；训练显存约 160 GB，推理显存约 12 GB，并表现出较强失败恢复能力

图 4-3 以柱状图直观对比三类变体的成功率与训练显存占用（批次大小为 4）：冻结主干变体在保持 90% 成功率的同时将训练显存从约 160 GB 降至约 60 GB，三类变体推理显存一致（均约 12 GB）。




图 4-3 三类模型变体成功率与显存对比

从上述对比中可以得到两点启示。

第一，桌面抓取任务更依赖短周期闭环修正，而不是长时间开环规划。因此，无论是部署时采用分段执行，还是训练时引入更适合失败恢复的记忆结构，本质上都是在增强“看见当前状态后迅速修正动作”的能力。

第二，小样本专用任务中的最优模型，不一定是参数更新最多的模型。对于 30 条示教数据这样的小规模任务，冻结部分主干、仅微调动作专家或少量适配参数，已经在补充实验中表现出更低训练显存占用和较高抓取成功率，说明其很可能在训练资源与最终性能之间取得更好的平衡。未来如果继续扩展数据量、增加苹果种类、改变桌面背景或加入更多失败恢复示教，再对这些变体做定量对比，将有助于形成更完整的桌面 VLA 训练经验。

结 论

本文围绕“面向桌面操作的视觉—语言—动作机械臂抓取与控制”这一课题，在 Franka FR3 七自由度机械臂与二指夹爪平台上，完成了从实时控制接入、LeRobot 通用接口扩展、示教数据采集与规范化，到 $\pi_{0.5}$ 模型迁移微调、变体改进与实机闭环部署的全栈技术链路。现按设计任务逐项总结完成情况。

T1——弗兰卡实时控制与 LeRobot 接口扩展（第二章）：设计并实现了四层系统架构（实时执行层—网络服务层—LeRobot 抽象层—遥操作与数据层）。在实时侧部署基于 libfranka 与 Ruckig 的实时控制服务进程，通过 TCP 套接字与上位机解耦，保证 1 kHz 底层控制与 ≥ 30 Hz 指令刷新频率。在 LeRobot 框架中实现了机器人抽象及夹爪复合配置，使本平台可被社区录制工具直接消费。在遥操作层面实现了三维鼠标笛卡尔增量与同构主从关节空间两种示教入口，并设计了交互式两阶段配对标定流程——第一阶段以一次对准姿态自动解算七轴缩放比例与偏置，第二阶段测量夹爪物理量程——将标定结果写入配置文件实现参数版本化。经标定后，主从映射的关节空间偏差均值控制在 1° 以内，示教轨迹的可重复性显著提升。

T2——桌面抓取示教数据采集与规范化（第二章）：以“抓取绿色苹果并放置至桌面左上角”为任务实例，采用双相机布局（第三人称固定相机与腕部手眼相机），通过同构主从臂完成精细示教，按 10 Hz 帧率同步录制了桌面抓取数据集。数据集严格遵循 LeRobot v2.1 目录规范：包含 30 条有效轨迹、5,512 帧、60 个视频轨道；元数据目录中定义了任务语义、轨迹信息及 8 维状态/动作特征描述，数据目录以列式存储格式存放帧级表格，视频目录存放双路 RGB 视频。数据集字段编排与 OpenPI 训练接口直接对齐，可被 LeRobot 数据加载器直接消费。

T3—— $\pi_{0.5}$ 模型迁移与变体改进（第三章、第四章）：将双视角观测、8 维状态/动作与自然语言提示映射至 OpenPI 训练接口，在加载 $\pi_{0.5}$ 预训练权重的基础上完成全量微调基线（成功率约 80%）。在此基础上，针对桌面任务小样本、接触敏感的特性，提出并实现了两项模型结构改进。第一项是冻结骨干轻量化变体：利用参数路径过滤机制精确冻结 VLM 骨干而仅微调动作专家，训练显存占用从约 160 GB 降至约 60 GB（批次大小为 4），成功率提升至 90%。第二项是短期记忆变体：在视觉编码器中引入空间-时间可分离注意力与时间位置编码，当前帧保留完整空间细节、历史帧压

缩为少量池化摘要 token，为模型提供短期视觉记忆；成功率达到 100%，并表现出自主失败恢复能力——在初次夹取失败后能够自发重新搜索目标并再次尝试抓取。

T4——实机闭环部署与在线执行策略对比（第三章）：针对同一模型权重在不同部署方式下可能产生截然不同实机表现的问题，设计并实施了受控对比实验。在同一训练完成的 $\pi_{0.5}$ 权重下，分别采用异步远端推理（执行完整动作块，偏长时开环）和分段同步闭环（每次仅执行动作块的一小段，约 0.27 s 后重新观测再推理）进行 10 次桌面苹果抓取测试。实验结果表明：异步开环方式成功率仅约 5%，失败集中在夹取接触瞬间的滑移与掉落；分段同步闭环方式成功率接近 100%，显著增强了接触阶段的在线修正与失败恢复能力。该对比量化了在线闭环策略对接触敏感任务的决定性作用——成功率差异超过 90 个百分点——验证了研究假设 H2，为 VLA 在类似桌面操作任务中的部署提供了可操作的工程准则。

创新点总结。本文的创新之处在于工程与方法的紧密结合。首先，弗兰卡-LeRobot 一体化接口与可版本化标定链路，将“通用硬件—标准数据—可复用训练栈”打通为可复现流程。其次，基于参数路径过滤的冻结骨干与基于空间-时间可分离注意力机制的短期记忆两项模型结构改进，通过配置驱动设计实现了训练显存效率与任务成功率的双重提升。再次，通过受控部署对比实验，首次在本平台桌面抓取场景中系统量化了闭环执行策略对 VLA 动作块预测模型的性能影响量级，揭示了“部署策略与模型结构同等重要”的工程规律。

不足与展望。受时间与数据规模限制，本文任务分布较窄（单一绿色苹果抓取），未系统评估跨物体、跨光照、跨台面布局的泛化能力。冻结骨干与短期记忆变体的超参数配置尚未充分网格化对比。部署对比仅在本平台上完成，尚未验证结论在其他机械臂平台上的可迁移性。后续工作可沿以下方向展开：扩展多物体、多姿态、多场景的示教数据集，结合数据增强提升策略泛化性；对模型变体进行更系统的超参数扫描与消融实验；将分段闭环部署策略推广至更复杂的多阶段长程任务；探索仿真到真实迁移与安全性约束下的在线策略切换机制。

总体而言，本文通过一条可复现的全栈技术路线证明了：先进 VLA 模型在静态桌面平台上的实用价值，不仅取决于模型本身的规模与预训练数据，更取决于与真实执行链路、标准化数据规范和在线闭环策略形成一致、可诊断的整体系统设计。这一结论对同类实验室平台引进与落地 VLA 技术具有参考意义。

参考文献

- [1] Black, K., Brown, N., Driess, D., et al. pi0: A Vision-Language-Action Flow Model for General Robot Control[J]. arXiv, 2024, 24164: 38-52.
- [2] Black, K., Brown, N., Darpinian, J., et al. pi0.5: A Vision-Language-Action Model with Open-World Generalization[J]. arXiv, 2025, 16054: 54-66.
- [3] Shridhar, M., Manuelli, L., Fox, D. CLIPORT: What and Where Pathways for Robotic Manipulation [J]. arXiv, 2021, 7747: 18-28.
- [4] Ahn, M., Brohan, A., Brown, N., et al. Do As I Can, Not As I Say: Grounding Language in Robotic Affordances[J]. arXiv, 2022, 1691: 44-58.
- [5] Jiang, Y., Gupta, A., Zhang, Z., et al. VIMA: General Robot Manipulation with Multimodal Prompts [J]. arXiv, 2022, 3094: 26-40.
- [6] Chen, B., Xu, Z., Kirmani, S., et al. SpatialVLM: Endowing Vision-Language Models with Spatial Reasoning Capabilities[C]//2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, WA, USA: IEEE, 2024.
- [7] Zhen, H., Qiu, X., Chen, P., et al. 3D-VLA: A 3D Vision-Language-Action Generative World Model [J]. arXiv, 2024, 9478: 26-40.
- [8] Ren, P., Zhang, K., Zheng, H., et al. Surfer: A World Model-Based Framework for Vision-Language Robot Manipulation[J]. IEEE Transactions on Neural Networks and Learning Systems, 2025, 36: 20092-20104.
- [9] Liu, P., Orru, Y., Vakil, J., et al. OK-Robot: What Really Matters in Integrating Open-Knowledge Models for Robotics[J]. arXiv, 2024, 12292: 18-30.
- [10] Driess, D., Xia, F., Sajjadi, M. S. M., et al. PaLM-E: An Embodied Multimodal Language Model [J]. arXiv, 2023, 3378: 32-48.
- [11] Bousmalis, K., Vezzani, G., Rao, D., et al. RoboCat: A Self-Improving Generalist Agent for Robotic Manipulation[J]. arXiv, 2023, 11736: 28-42.
- [12] Shridhar, M., Manuelli, L., Fox, D. PERCEIVER-ACTOR: A Multi-Task Transformer for Robotic Manipulation[J]. arXiv, 2022, 5451: 20-34.
- [13] 赵博涛, 亢祖衡, 瞿晓阳, 等. 基于多模态大模型的具身智能体研究进展与展望[J]. 大数据, 2025, 11: 108-138.
- [14] Brohan, A., Brown, N., Carbajal, J., et al. RT-1: Robotics Transformer for Real-World Control at Scale[J]. arXiv, 2022, 6817: 36-50.
- [15] Brohan, A., Brown, N., Carbajal, J., et al. RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control[J]. arXiv, 2023, 15818: 40-56.
- [16] O'Neill, A., Rehman, A., Maddukuri, A., et al. Open X-Embodiment: Robotic Learning Datasets and RT-X Models[C]//2024 IEEE International Conference on Robotics and Automation (ICRA). Yokohama, Japan: IEEE, 2024.
- [17] Kim, M. J., Pertsch, K., Karamcheti, S., et al. OpenVLA: An Open-Source Vision-Language-Action Model[J]. arXiv, 2024, 9246: 24-38.
- [18] Ghosh, D., Walke, H., Pertsch, K., et al. Octo: An Open-Source Generalist Robot Policy[J]. arXiv, 2024, 12213: 30-44.

- [19] Wang, S., Li, X., Chen, C., et al. RoboFlamingo-Plus: Fusion of Depth and RGB Perception with Vision-Language Models for Enhanced Robotic Manipulation[J]. arXiv, 2025, 19510: 22-34.
- [20] Nasiriany, S., Maddukuri, A., Zhang, L., et al. RoboCasa: Large-Scale Simulation of Everyday Tasks for Generalist Robots[J]. arXiv, 2024, 2523: 24-38.
- [21] Tao, S., Yuan, C., Wu, Y., et al. ManiSkill3: GPU Parallelized Robot Simulation and Rendering for Generalizable Embodied AI[J]. arXiv, 2024, 425: 18-30.
- [22] Ahn, M., Dwibedi, D., Finn, C., et al. AutoRT: Embodied Foundation Models for Large Scale Orchestration of Robotic Agents[J]. arXiv, 2024, 12963: 28-42.
- [23] Cheang, C.-L., Chen, G., Jing, Y., et al. GR-2: A Generative Video-Language-Action Model with Web-Scale Knowledge for Robot Manipulation[J]. arXiv, 2024, 6158: 32-46.
- [24] 李牧, 刘雪峰, 李青锋, 等. 基于扩散模型的具身智能模仿学习综述[J]. 中国科学: 信息科学, 2026, 56: 245-276.
- [25] Amin, A., Aniceto, R., Balakrishna, A., et al. $\pi_{0.6}^*$: A VLA That Learns From Experience[J]. arXiv, 2025, 14759: 48-62.
- [26] Pertsch, K., Stachowicz, K., Ichter, B., et al. FAST: Efficient Action Tokenization for Vision-Language-Action Models[C]//Proceedings of Robotics: Science and Systems. Los Angeles, CA, USA: RSS, 2025.
- [27] Driess, D., Springenberg, J. T., Ichter, B., et al. Knowledge Insulating Vision-Language-Action Models: Train Fast, Run Fast, Generalize Better[J]. arXiv, 2025, 3700: 34-48.
- [28] Beyer, L., Steiner, A., Pinto, A. S., et al. PaliGemma: A Versatile 3B VLM for Transfer[J]. arXiv, 2024, 7726: 22-36.
- [29] Lipman, Y., Chen, R. T. Q., Ben-Hamu, H., et al. Flow Matching for Generative Modeling[C]//Proceedings of the International Conference on Learning Representations. Kigali, Rwanda: Open-Review, 2023.
- [30] Fu, Z., Zhao, T. Z., Finn, C. Mobile ALOHA: Learning Bimanual Mobile Manipulation with Low-Cost Whole-Body Teleoperation[J]. arXiv, 2024, 2117: 16-28.
- [31] Zhao, T. Z., Tompson, J., Driess, D., et al. ALOHA Unleashed: A Simple Recipe for Robot Dexterity[J]. arXiv, 2024, 4798: 20-32.
- [32] Wen, C., Lin, X., So, J., et al. Any-point Trajectory Modeling for Policy Learning[J]. arXiv, 2023, 842: 14-26.
- [33] Ye, B., Fan, N., Fan, Z., et al. FlyAware: Inertia-Aware Aerial Manipulation via Vision-Based Estimation and Post-Grasp Adaptation[J]. IEEE Robotics and Automation Letters, 2026, 11: 3780-3787.
- [34] Black, K., Driess, D., Finn, C., et al. MEM: Multi-Scale Embodied Memory for Vision Language Action Models[J]. arXiv, 2025, 2603.03596: 1-24.

附 录

附录 A 缩略语与符号说明

表 A-1 文中常用缩略语

缩略语	英文全称及中文含义
VLA	Vision-Language-Action, 视觉—语言—动作（模型）
VLM	Vision-Language Model, 视觉—语言模型
IK	Inverse Kinematics, 逆运动学
RGB	Red-Green-Blue, 三通道彩色图像
RT PC	Real-Time PC, 机器人实时控制计算机
TCP	Transmission Control Protocol, 传输控制协议
API	Application Programming Interface, 应用程序接口

文中若干符号与第二、三章公式一致：主从关节映射中 α_i 、 β_i 分别为第 i 轴缩放与偏置；夹爪归一化量记为 $g_{[0,1]}$ ； $\pi_{0.5}$ 的策略分解记法见第三章式(3-1) 与式(3-2)。自采数据集的帧级特征键名见第二章表 2-2。

附录 B 实验与工程环境概要

机器人与控制：弗兰卡七轴协作臂，末端配置二指电驱夹爪；实时侧运行基于官方 libfranka 的实时控制服务，轨迹平滑采用 Ruckig 库；上位机与实时机通过局域网套接字交互。

感知与遥操作：第三人称与腕部 RGB 相机（ 1280×720 、标称 10 Hz）；三维鼠标用于笛卡尔增量示教；同构主从由主臂读数经标定后映射至从臂关节目标。配对标定流程详见第二章。

软件栈：操作系统以 Ubuntu 22.04 LTS 为主；Python 侧基于 Hugging Face LeRobot 约定版本扩展 Robot 与 Teleoperator 接口；策略训练与远端推理基于 OpenPI ($\pi_{0.5}$)；可视化抽检可使用 Rerun。具体依赖版本以毕业设计代码仓库锁定的环境为准，附录不替代版本管理文件。

附录 C LeRobot 配置类型速查

表 C-2汇总第二章所述主要 type 字段，便于部署时对照；详述与类名仍以第二章表 2-1 及正文为准。

表 C-2 本文扩展的 LeRobot 配置 type 速查

type	简要说明
franka_fer	弗兰卡从臂，关节目标动作，无独立夹爪通道
franka_fer_gripper	臂 + 夹爪八维观测与动作
franka_fer_spacemouse	三维鼠标遥操作（臂）
franka_fer_gripper_spacemouse	三维鼠标遥操作（臂 + 夹爪）
franka_fer_subarm	同构主从关节映射（臂）
franka_fer_gripper_subarm	同构主从关节映射（臂 + 夹爪）

致 谢

转眼间，四年的本科学习生活即将画上句号。回望入学时的青涩与此刻略增的笃定，我深知成长离不开师长、家人与同伴的扶持与包容。在此，谨向所有帮助过我的人们致以诚挚谢意。

首先要衷心感谢导师方浩教授。方老师在选题凝练、文献脉络与技术路线取舍上耐心点拨，并在论文结构与表述细节上严格要求、反复批注，帮助我建立更条理的写作习惯；在实验受挫与文稿屡次返工的阶段，也以具体问题牵引我逐项改进。课题组为本课题配置了难得的实验条件：高性能计算资源、弗兰卡协作机械臂及知行末端夹爪、深度相机等感知器件，使许多设想得以工程化验证。正是在控制器接口打通、LeRobot 数据规范对齐以及模型训练与实机部署等环节的支持下，我才把阶段性构想落实为可运行、可评测的系统，顺利完成毕业设计。

其次要感谢父母与家人，在生活琐事与情绪波动时给予的照料与理解；正是这份稳定依靠，让我衣食无忧，也能更安心地求学与科研。

我还要感谢同窗与合作者。陈禹佟是本课题最密切的搭档：实验方案论证、示教采集与数据抽检、训练配置对齐以及实机闭环对比与结果整理，我们在一次次并肩推进中学会分工与担当；联调排错中的并肩作战，也成为本科阶段难忘的记忆。刘恒华承担主动臂结构设计及 RealSense 安装件建模打印，关乎装配与视野的细节直接影响平台可用性。感谢机器人队伙伴们，与你们在调试与讨论中的相处让我保持工程敏感与合作信任。亦感谢李思捷、冷龙康、王晨宇、朱培炎等好友，学业建议与生活陪伴让大学四年充实温暖。

最后感谢母校北京理工大学提供的课堂、实验室与社团土壤。四年里我积累了专业知识与工程方法，也更懂得在压力下自我调节、在分歧中寻求共识。这段经历未必尽善尽美，却足够真诚；它将鞭策我以更踏实的心态走向下一阶段的人生旅途。